PROJET DE DATA SCIENCE

Prédire si un client va souscrire à une offre

Étude réalisée à partir du jeu de données

Bank Marketing Dataset



Début du projet : Août 2026

Fin du projet : Août 2026

Nom et prénom :	Ngomo Luigy
Niveau d'études :	Master 2
Diplôme :	Mathématiques appliquées, statistiques et Data Science
Dernière expérience professionnelle :	Enseignant de Mathématiques et d'Algorithmique appliquée
Profil LinkedIn :	www.linkedin.com/in/luigy-ngomo-7129312a6
Adresse électronique :	ngomoluigy@gmail.com

Résumé

Cette étude est une étude de classification binaire qui porte sur la prédiction à la souscription à une offre bancaire à partir des informations disponibles dans le *Bank Marketing Dataset*.
Dans cette étude, nous construisons, comparons et interprétons les résultats de plusieurs modèles prédictifs capables prédire si un client va souscrire à l'offre à partir de ses caractéristiques personnelles, sa situation financière et des informations de la campagne marketing.
Le travail comprend notamment le traitement des valeurs manquantes, le traitement des valeurs aberrantes, l'analyse des corrélations, la création de nouvelles variables, l'encodage des variables catégorielles, l'entraînement de plusieurs modèles de machine learning et la comparaison de leur performance sur un ensemble de validation indépendant, l'explication SHAP à trois niveaux des résultats de prédictions, etc.
Les modèles utilisés pour les prédictions sont notamment : XGBoost classifier et LightGBM classifier.

Expressions et notions importantes à connaître : classification binaire, Bank Marketing Dataset, feature engineering, machine learning, XGBoost, LightGBM, tuning d'hyperparamètres, validation croisée stratifiée k-fold, courbe ROC, AUC, précision, rappel, F1-score, interprétabilité, contribution SHAP, dépôt à terme bancaire, prêt immobilier, prêt personnel, seuil de classification, vrai positif, faux positif, vrai négatif, faux négatif, probabilités conditionnelles, intégrale, aire sous la courbe, classe positive, classe négative, espérance conditionnelle, fonction logistique, etc.

Table des matières

Résumé **1**

I Introduction **5**

II Chargement et familiarisation avec les données **5**
II.1 Chargement des données 5
II.2 Familiarisation avec les données 6

III Analyse exploratoire des données **7**
III.1 Distributions de la variable cible 'y' 7
III.2 Gestion des valeurs manquantes 8
III.3 Gestions des valeurs uniques et des valeurs doubles 8
III.4 Gestions des valeurs aberrantes 8
III.5 Corrélations 10
III.6 Distributions des variables catégorielles 11

IV Feature engineering **13**
IV.1 Feature creation 13
IV.2 Encodage des variables catégorielles dichotomiques 14
IV.3 Count Encoding ou Frequency Encoding des variables catégorielles 15
IV.4 Label Encoding et croisement de paires de variables catégorielles 17
IV.5 One-Hot-Encoding des variables catégorielles restantes 19

V Optimisation des hyperparamètres **21**
V.1 Plages de recherche des hyperparamètres 22
V.2 Validation croisée stratifiée k-fold 23
V.3 Temps d'optimisation et choix du nombre d'essais et de folds 24

VI Entrainement et évaluation finale des modèles **26**
VI.1 De la probabilité prédite à la classification 26
VI.2 Influence du seuil de classification 26
VI.3 Construction et interprétation de la courbe ROC 28
VI.4 L'AUC : aire sous la courbe ROC 29
VI.5 L'AUC est comprise entre 0 et 1 30
VI.6 Interprétation des valeurs de l'AUC 31
VI.7 Résultats sur l'ensemble test 31
VI.7.1 Comparaison rappel et AUC-ROC des deux modèles 31
VI.7.2 Rapports de classification 32
VI.7.3 Matrices de confusion 33
VI.7.4 Courbes ROC 34

VII Explication des résultats de prédictions du modèle avec SHAP **34**
VII.1 Explication globale 35
VII.1.1 Moyenne des valeurs absolues des contributions SHAP d'une variable 35
VII.2 La valeur absolue maximale des contributions SHAP en valeur absolue d'une variable 36
VII.2.1 Graphique de synthèse de la distribution des valeurs SHAP des variables 38
VII.3 Explication au niveau des variables 40
VII.3.1 Graphique de dépendance partielle 40
VII.4 Explication locale 42
VII.4.1 Graphique de forces (Force Plot) d'un client 42
VII.4.2 Graphique en cascade (Waterfall Plot) d'un client 43

Références **48**

Table des figures

1 Aperçu du Bank Marketing dataset . . . 6
2 Distribution de la variable cible . . . 7
3 Distributions des variables numériques . . . 9
4 Quelques caractéristiques des 10 premiers clients avec le nombre de contact avant la campagne le plus élevé . . . 10
5 Matrice de corrélations . . . 10
6 Distribution des variables catégorielles . . . 11
7 Croisement des variables statut matrimonial et niveau d'éducation . . . 12
8 Croisement des variables résultat de la campagne précédente et type de contact . . . 12
9 Temps d'éxécution du tuning d'hyperparamètres par modèles . . . 25
10 Seuil de séparation et FPR associé . . . 27
11 Exemple de courbe ROC d'un bon modèle . . . 29
12 Matrices de confusion des deux modèles de classification . . . 33
13 Courbe ROC des deux modèles de classification . . . 34
14 Importance globale moyenne SHAP des variables . . . 36
15 Importance absolue SHAP des variables . . . 37
16 Beeswarm plot des variables . . . 38
17 Graphique de dépendance partielle de la variable 'duration' . . . 41
18 Graphique de dépendance partielle de la variable 'balance' . . . 42
19 Waterfall plot du client prédit comme souscripteur . . . 44
20 Force plot du client prédit comme souscripteur . . . 45
21 Waterfall plot du client prédit comme non-souscripteur . . . 46
22 Force plot du client prédit comme non-souscripteur . . . 46

I Introduction

Le but de ce projet est de prédire si un client va souscrire à un dépôt à terme bancaire puis d'identifier et analyser les caractéristiques qui influencent le plus la décision de souscription.
Le jeu de donnée utilisé est le jeu de donnée Bank Marketing Dataset Full qui contient les informations sur les clients d'une institution bancaire portugaise. Ces données ont été obtenues à partir d'une campagne de marketing directe, et chaque entrée correspond à un client unique.
A ce jeu de donnée, nous avons ajouté des données synthétiques générées en utilisant un modèle de deep learning entraîné sur le jeu de données originales. Les distributions des variables des données générées sont très proches de celles des données originales, bien qu'elles ne soient pas identiques.
Le jeu de données final contient alors n observations (clients) et p variables explicatives qui représentent les informations clients ainsi que les détails de la campagne.
La variable cible que l'on souhaite prédire est la variable binaire y qui renseigne si oui (1) ou non (0) le client à souscrit à l' offre.
Les variables qui expliquent ou tentent d'expliquer ce résultat sont par exemple :

- l'age du client (age),
- le type d'emploi du client (job),
- la situation marital du client (marital),
- la durée du dernier contact en secondes (duration),
- type de contact utilisé (contact),
- le niveau d'éducation du client (education),
- le client a t'il un pret immobilier ? (housing),
- solde moyen annuel du client (balance)
- etc.

C'est donc un problème de classification binaire. Pour prédire la variable y à partir de l'information renvoyée par les variables explicatives, nous utiliserons plusieurs algorithmes différents de machine learning.

II Chargement et familiarisation avec les données

II.1 Chargement des données

Les données au format csv, nous les lisons en python en utilisans pandas :

```
Taille des données synthétiques : (750000, 17)

Taille des données originales : (45211, 17)

Taille du dataset final : (795211, 17)
```

age	job	marital	education	default	balance	housing	loan	contact	day	month	duration	campaign	pdays	previous	poutcome	y
42	technician	married	secondary	no	7	no	no	cellular	25	aug	117	3	-1	0	unknown	0
38	blue-collar	married	secondary	no	514	no	no	unknown	18	jun	185	1	-1	0	unknown	0
36	blue-collar	married	secondary	no	602	yes	no	unknown	14	may	111	2	-1	0	unknown	0
27	student	single	secondary	no	34	yes	no	unknown	28	may	10	2	-1	0	unknown	0
26	technician	married	secondary	no	889	yes	no	cellular	3	feb	902	1	-1	0	unknown	1

FIGURE 1 – Aperçu du Bank Marketing dataset

II.2 Familiarisation avec les données

Nous affichons ci-dessous quelques informations sur le jeu de données afin de mieux nous familiarisé avec ce dernier :

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 795211 entries, 0 to 795210
Data columns (total 17 columns):
 #   Column     Non-Null Count   Dtype
---  ------     --------------   -----
 0   age        795211 non-null  int64
 1   job        795211 non-null  object
 2   marital    795211 non-null  object
 3   education  795211 non-null  object
 4   default    795211 non-null  object
 5   balance    795211 non-null  int64
 6   housing    795211 non-null  object
 7   loan       795211 non-null  object
 8   contact    795211 non-null  object
 9   day        795211 non-null  int64
 10  month      795211 non-null  object
 11  duration   795211 non-null  int64
 12  campaign   795211 non-null  int64
 13  pdays      795211 non-null  int64
 14  previous   795211 non-null  int64
 15  poutcome   795211 non-null  object
 16  y          795211 non-null  object
```

On peut voir une fois de plus que le jeu de données possède 795 211 observations (clients) et 17 variables. Il y a 2 type de donnés : int64 (entier) et object (texte). Aucune variable ne contient des valeurs manquantes (NAN).

Nous affichons ci-dessous quelques informations résumées sur la variable cible 'y' :

```
Taille du jeu de données : (795211, 17)

Répartition de la variable cible 'y' :
y
0    699434
1     95777

Répartition en pourcentage :
y
0    87.96
1    12.04
```

On constate que environ 12% seulement des clients ciblés par la campagne marketing ont souscrit au dépôt à terme bancaire.

III Analyse exploratoire des données

III.1 Distributions de la variable cible 'y'

On rappelle que la variable cible 'y' est telle que :

$$y = \begin{cases} 1(oui) & \text{si le client a souscrit à l'offre.} \\ 0(non) & \text{si le client n'a pas souscrit à l'offre,} \end{cases}$$

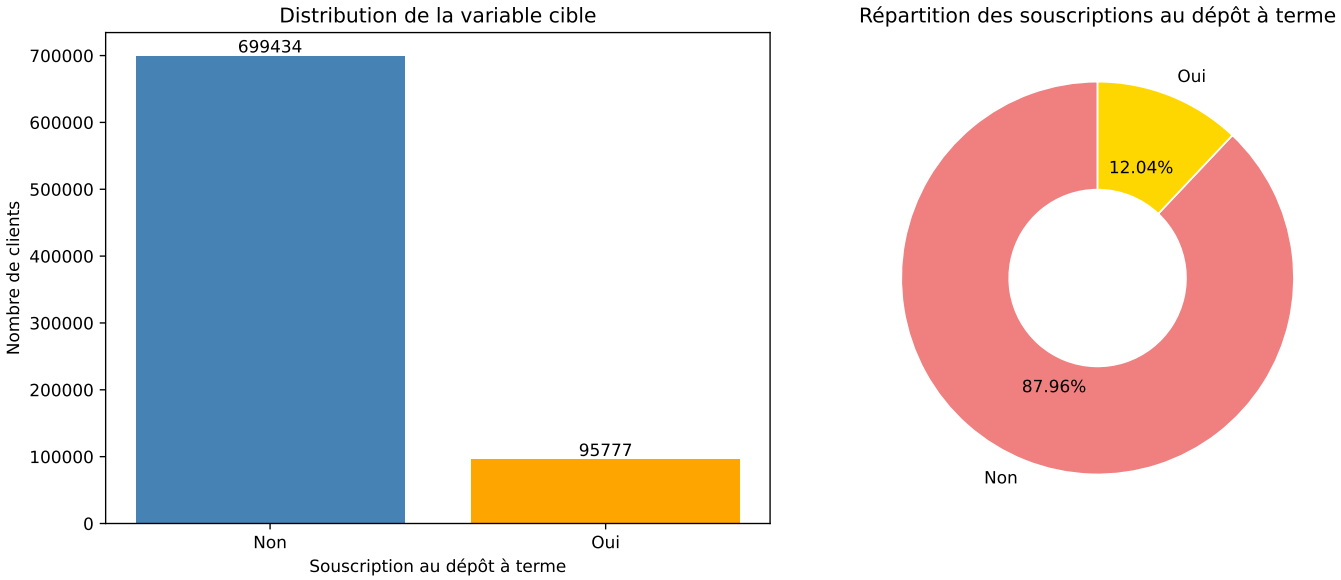


FIGURE 2 – Distribution de la variable cible

III.2 Gestion des valeurs manquantes

Comme remarqué précédemment, le jeu de données ne contient aucune valeur manquante :

```
Nombre de valeurs manquantes par variable :
age          0
job          0
marital      0
education    0
default      0
balance      0
housing      0
loan         0
contact      0
day          0
month        0
duration     0
campaign     0
pdays        0
previous     0
poutcome     0
y            0
```

III.3 Gestions des valeurs uniques et des valeurs doubles

Le dataset ne contient aucunes observations doubles :

```
Nombre de lignes dupliquées : 0

Nombre de lignes uniques : 795211
```

III.4 Gestions des valeurs aberrantes

Nous visualisons ci-dessous les histogrammes et les boxplots des variables numériques du dataset :

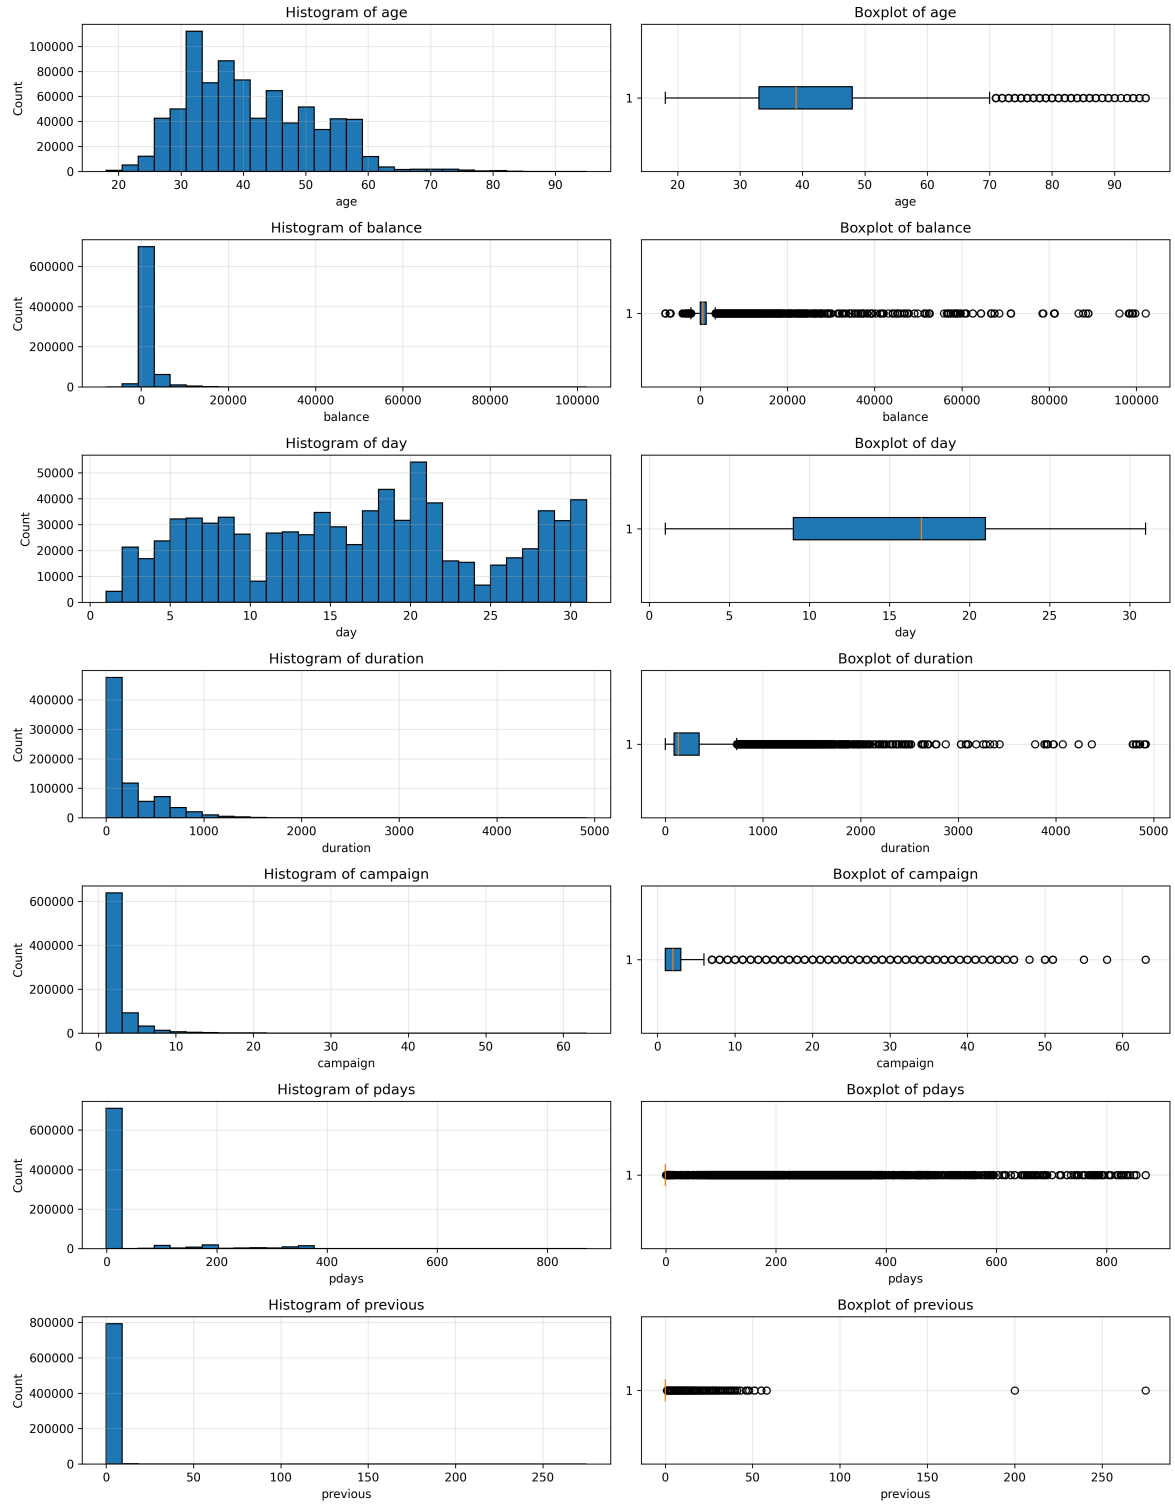


FIGURE 3 – Distributions des variables numériques

La distribution de la variable previous met en évidence deux observations particulièrement élevées par rapport aux autres observations. En effet, deux clients auraient quasiment été contactés au moins 200 fois avant la campagne actuelle. Ces valeurs pourraient constituer des valeurs aberrantes. Avant d'envisager de les supprimées, nous examinons les autres caractéristiques de ces clients pour déterminer si les observations paraissent incohérentes :

previous	pdays	campaign	housing	loan	balance	duration	poutcome	y
275	262	2	yes	no	543	349	other	0
200	100	1	no	no	0	7	other	0
58	459	1	no	yes	-306	138	other	0
58	353	2	yes	yes	1085	523	other	1
55	189	3	no	no	613	808	failure	1
55	285	5	yes	no	1402	106	failure	0
55	776	3	yes	no	432	386	failure	1
51	426	3	yes	no	0	439	other	1
51	350	2	yes	no	1465	98	failure	0
51	324	8	yes	yes	794	25	failure	0

FIGURE 4 – Quelques caractéristiques des 10 premiers clients avec le nombre de contact avant la campagne le plus élevé

En effet, en regardant les 10 plus grandes valeurs de la variable previous, on constate que les valeurs 200 et 275 sont extrêmement isolées, puisque la troisième valeur la plus élevée de previous n'est que 58. Cependant, après examen des autres caractéristiques des deux clients concernés, aucune incohérence particulière n'est identifiée. Ces observations sont donc conservées dans le jeu de données.

III.5 Corrélations

Nous affichons ci-après la matrice de corrélations des variables numériques quantitatives :

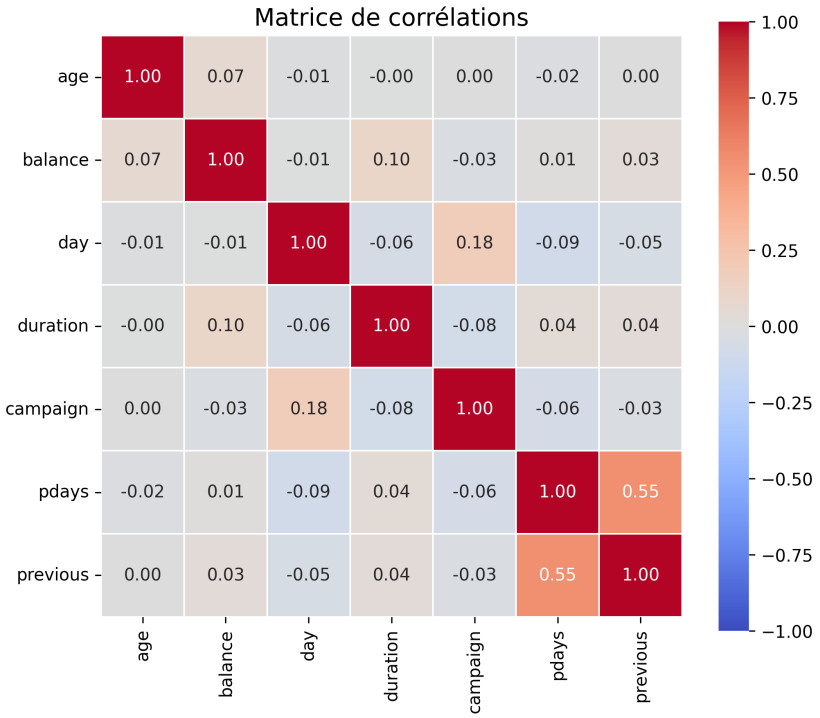


FIGURE 5 – Matrice de corrélations

La matrice de corrélation met en évidence des relations linéaires globalement faibles entre les variables numériques. La relation la plus marquée concerne pdays et previous, avec une corrélation positive modérée de $0,55$. L'absence de fortes corrélations linéaires n'exclut cependant pas l'existence de relations non linéaires entre certaines variables.

III.6 Distributions des variables catégorielles

Nous affichons ci-dessous les distributions de chaque variable catégorielle :

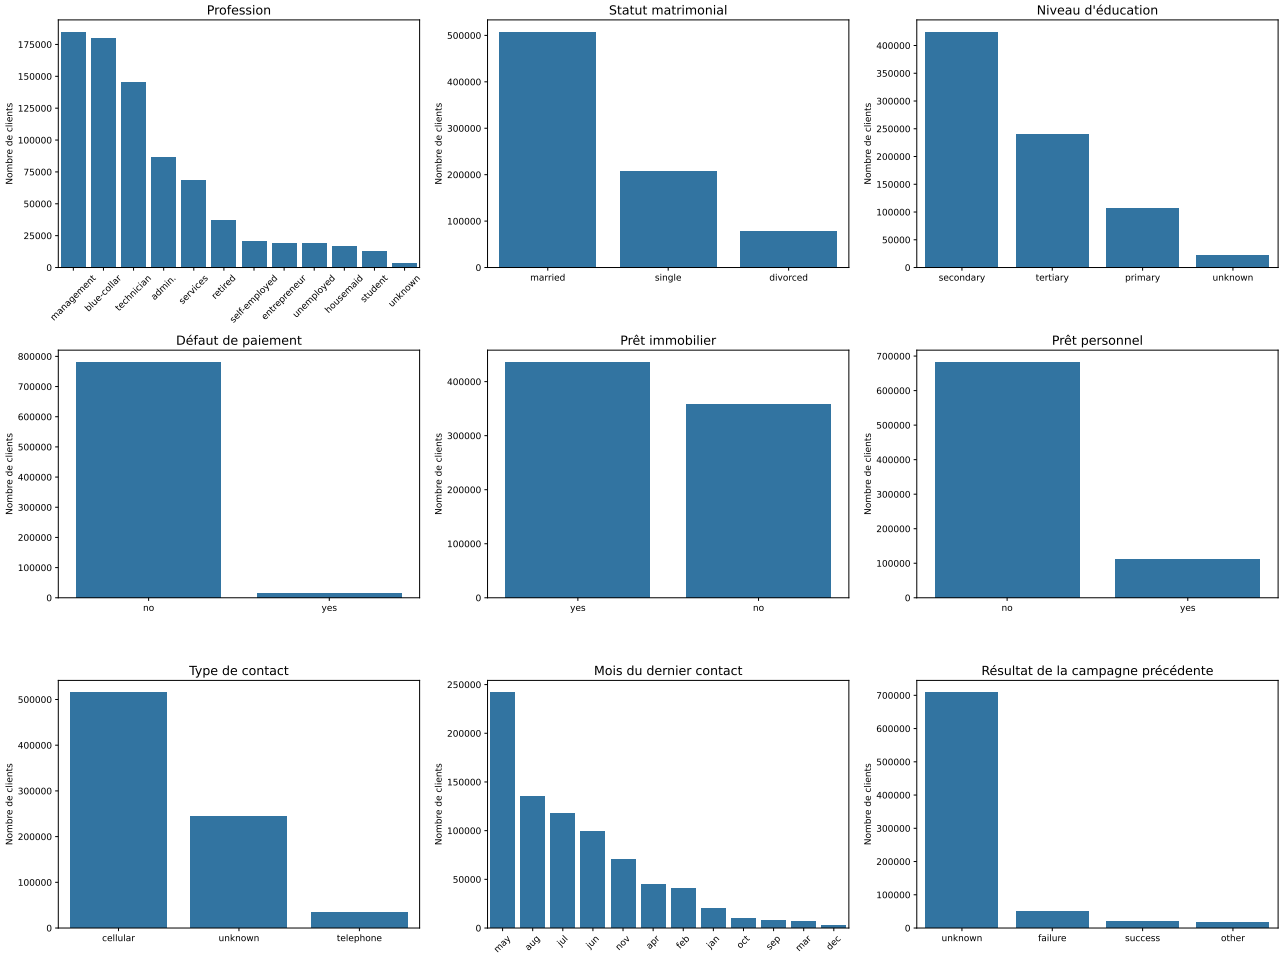


FIGURE 6 – Distribution des variables catégorielles

Nous présentons ci-dessous les croisements de certaines variables catégorielles du jeu de données :

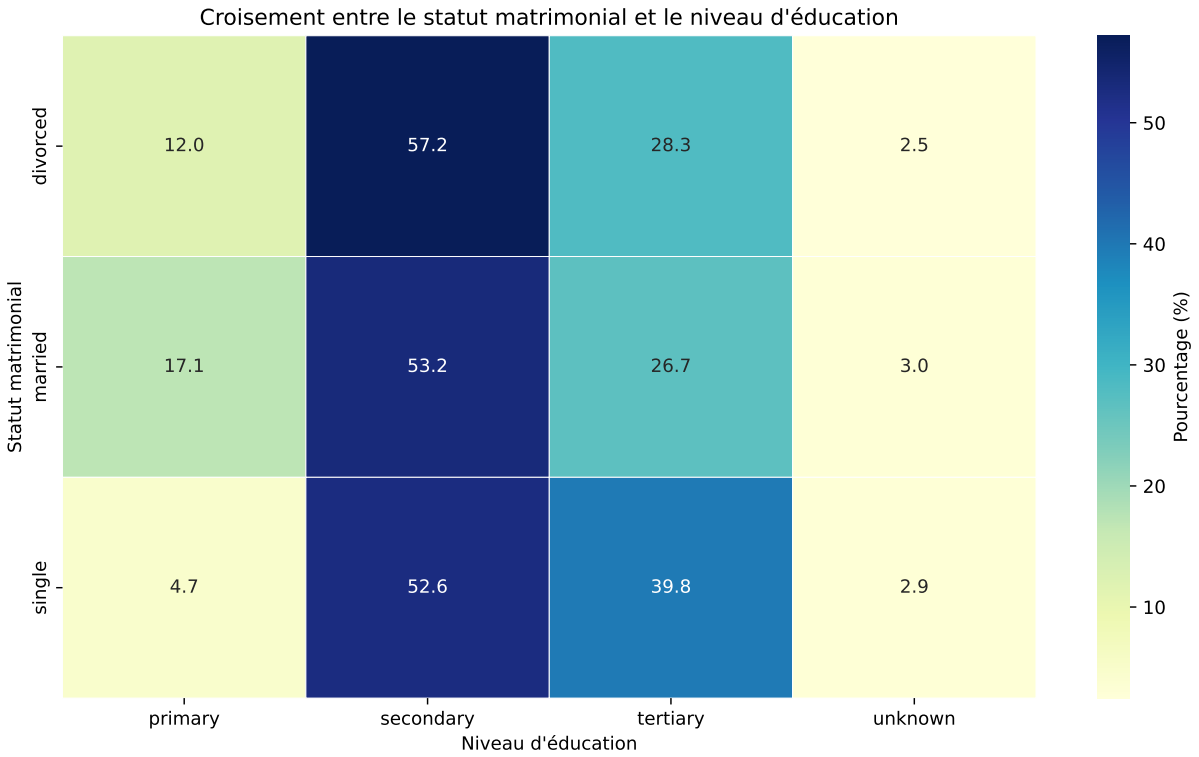


FIGURE 7 – Croisement des variables statut matrimonial et niveau d'éducation

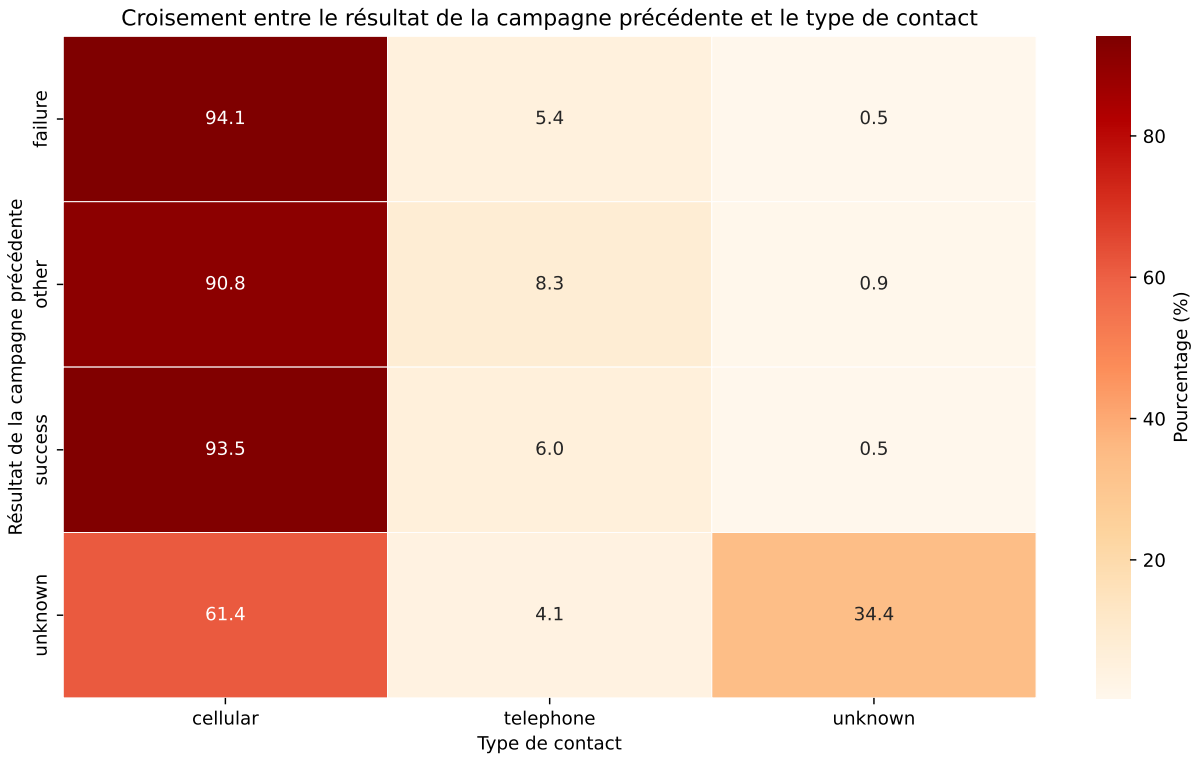


FIGURE 8 – Croisement des variables résultat de la campagne précédente et type de contact

IV Feature engineering

IV.1 Feature creation

Dans cette sous-section, nous créons plusieurs nouvelles variables à partir des variables déjà présentes dans le jeu de données. Les variables créées sont les suivantes :
balance_pos : variable qui vaut 1 si le solde moyen annuel ('balance') est strictement positif et 0 sinon.
had_previous : variable qui vaut 1 si le nombre de jours écoulés depuis le dernier contact effectué lors d'une campagne précédente ('pdays') est strictement positif et 0 sinon.
campaign_int : variable qui découpe le nombre de contacts effectués auprès du client durant la campagne ('campaign') en différents niveaux d'intensité. Chaque client se voit ainsi attribuer le niveau correspondant à l'intervalle dans lequel se trouve son nombre de contacts durant la campagne :

- de 0 à 2 contacts ——> niveau bas ('low')
- de 3 à 5 contacts ——> niveau moyen ('medium')
- de 6 à 9 contacts ——> niveau élevé ('high')
- de 10 jusqu'à la valeur maximale ——> niveau extrême ('extreme')

previous_succeed : variable qui vaut 1 si la campagne précédente ('poutcome') s'est terminée par un succès ('success') et 0 sinon.
poutcome_know : variable qui vaut 1 si l'issue de la campagne précédente ('poutcome') n'est pas inconnue ('unknown'), et 0 sinon.
contact_know : variable qui vaut 1 si le moyen de communication utilisé pour contacter le client ('contact') n'est pas inconnu ('unknown'), et 0 sinon.
education_know : variable qui vaut 1 si le niveau d'éducation du client ('education') n'est pas inconnu ('unknown'), et 0 sinon.
job_know : variable qui vaut 1 si le type d'emploi du client ('job') n'est pas inconnu ('unknown'), et 0 sinon.
Ensuite, nous encodons de manière cyclique la variable 'day'. Chaque jour du mois est alors représenté par un point sur le cercle trigonométrique :

- **day_sin** $= \sin\left(2\pi \times \frac{day}{31}\right)$
- **day_cos** $= \cos\left(2\pi \times \frac{day}{31}\right)$

Ces deux variables permettent ainsi d'encoder cycliquement la variable 'day', qui représente le jour du mois du dernier contact (1 à 31). La variable 'day' d'origine est ensuite supprimée.
Nous présentons ci-après le bilan de cette sous-section :

```
===== BILAN DE LA FEATURE CREATION =====

Nombre de nouvelles variables créées : 10

Nouvelles variables créées :
- balance_pos
- had_previous
- campaign_int
- previous_succeed
- poutcome_know
- contact_know
- education_know
- job_know
- day_sin
- day_cos

Nombre de variables catégorielles explicatives restantes : 10

Variables catégorielles explicatives restantes :
- job
- marital
- education
- default
- housing
- loan
- contact
- month
- poutcome
- campaign_int

Nombre de variables avant Feature Creation : 17
Nombre total de variables après Feature Creation : 26
```

IV.2 Encodage des variables catégorielles dichotomiques

Les variables catégorielles dichotomiques (yes ou no) du jeu de données sont : default, housing et loan. Nous encodons ces variables par des 0 et des 1.

$$default = \begin{cases} 1 & \text{si le client a un crédit en défaut.} \\ 0 & \text{si le client n'a pas de crédit en défaut} \end{cases}$$

$$housing = \begin{cases} 1 & \text{si le client a un prêt immobilier} \\ 0 & \text{si le client n'a pas de prêt immobilier} \end{cases}$$

$$loan = \begin{cases} 1 & \text{si le client a un prêt personnel} \\ 0 & \text{si le client n'a pas de prêt personnel} \end{cases}$$

A ce stage il nous reste donc 7 variables catégorielles dans le jeu de données, à savoir : job, marital, education, contact, month, poutcome et campaign_int.

```
===== BILAN APRÈS ENCODAGE DES VARIABLES DICHOTOMIQUES =====

Variables encodées :
- default
- housing
- loan

Nombre de variables catégorielles explicatives restantes : 7

Variables catégorielles explicatives restantes :
- job
- marital
- education
- contact
- month
- poutcome
- campaign_int

Nombre total de variables dans le jeu de données : 26
```

IV.3 Count Encoding ou Frequency Encoding des variables catégorielles

Le count encoding pour une variable consiste à remplacer chaque modalité de cette variable par son nombre total d'apparition au seins de celle-ci.
Par exemple pour la variable education, on a :

```
Répartition de la variable 'education' :
education
secondary    424885
tertiary     240809
primary      106361
unknown       23156
```

Donc, cette variable peut ensuite être encodée en remplaçant chaque occurrence de secondary par 424 885, de tertiary par 240 809, de primary par 106361 et de unknown par 23 156.
Une variante de cette approche est le frequency encoding. Il consiste cette fois, non pas à remplacer chaque modalité par son nombre total d'apparition mais plutôt par sa fréquence

d'apparition dans le jeu de données.
Ainsi toujours pour la variable education, on a :

```
Répartition en pourcentage :
education
secondary    0.53
tertiary     0.30
primary      0.13
unknown      0.03
```

Et donc, chaque occurrence de secondary sera remplacée par $0,53$, de tertiary par $0,30$, de primary par $0,13$ et de unknown par $0,03$.
C'est cette approche que nous utilisons dans cette étude. Elle sera appliquée aux 7 variables catégorielles restantes du jeu de données : job, marital, education, contact, month, poutcome et campaign_int. Les 7 nouvelles variables obtenues par frequency encoding sont ajoutées aux variables déjà présentes dans le jeu de données. Les 7 variables catégorielles d'origine ne sont donc pas supprimées : elles seront conservées dans le jeu de données en plus de leur équivalent encodé par fréquence.

```
===== BILAN APRÈS FREQUENCY ENCODING =====

Nombre de nouvelles variables créées par Frequency Encoding : 7

Nouvelles variables créées :
- job_freq
- marital_freq
- education_freq
- contact_freq
- month_freq
- poutcome_freq
- campaign_int_freq

Nombre de variables catégorielles explicatives restantes : 7

Variables catégorielles explicatives restantes :
- job
- marital
- education
- contact
- month
- poutcome
- campaign_int

Nombre total de variables dans le jeu de données : 33
```

IV.4 Label Encoding et croisement de paires de variables catégorielles

Le label encoding consiste à attribuer un numéro à chaque modalité d'une variable catégorielle. Par exemple, la variable catégorielle 'education' possède les modalités : 'secondary', 'tertiary', 'primary' et 'unknown'. En la label encodant, on peut par exemple attribuer le numéro 0 à la modalité 'secondary', le numéro 1 à 'tertiary', le numéro 2 à 'primary' et le numéro 3 à 'unknown'.
De même, la variable catégorielle 'marital' possède les modalités 'married', 'single' et 'divorced', que l'on pourrait par exemple encoder par 0 pour 'married', 1 pour 'single' et 2 pour 'divorced'.
Bien sûr, il n'y a aucune relation numérique particulière entre ces différents numéros : ce sont simplement des étiquettes numériques attribuées aux différentes modalités.

Dans cette étude, nous effectuons un label encoding sur les 7 variables catégorielles restantes du jeu de données : 'job', 'marital', 'education', 'contact', 'month', 'poutcome' et 'campaign_int'.
Ensuite, nous effectuons un croisement deux à deux de toutes les combinaisons possibles de ces 7 variables. Chaque paire de variables donne ainsi naissance à une nouvelle variable catégorielle représentant les différentes combinaisons de leurs modalités.
On rappelle qu'en mathématiques, le nombre de combinaisons possibles (ou nombre de parties possibles) à p éléments d'un ensemble qui en contient n est donné par la formule :

$$\binom{n}{p} = \frac{n!}{p!(n-p)!}$$

où n et p sont des entiers naturels et où la factorielle $n!$ est définie comme le produit des entiers de 1 à n :

$$n! = 1 \times 2 \times 3 \times \cdots \times (n-1) \times n$$

Par convention, $0! = 1$ et $1! = 1$.
Dans notre cas, nous cherchons toutes les paires possibles parmi 7 variables catégorielles. On a donc :

$$\binom{7}{2} = \frac{7!}{2!(7-2)!} = \frac{7!}{2!5!} = \frac{7 \times 6}{2 \times 1} = 21$$

On aura donc au total **21 nouvelles variables** issues du croisement deux à deux des 7 variables catégorielles. Pour chaque nouvelle variable créée, il faut ensuite attribuer un numéro unique à chacune de ses modalités lesquelles sont issues des combinaisons des modalités des deux variables combinées. Pour cela, nous utilisons la formule suivante :

$$\text{num_modalité_nouv_col} = \text{num_modalité_C1} \times \text{long(C2)} + \text{num_modalité_C2}$$

où num_modalité_C1 représente le numéro de la modalité de la première variable, num_modalité_C2 le numéro de la modalité de la deuxième variable, long(C2) le nombre de modalités de la deuxième variable et num_modalité_nouv_col le numéro attribué à la combinaison correspondante dans la nouvelle variable.
On notera que la formule précédente permet en effet d'obtenir un numéro unique pour chaque modalité à condition que :

$$0 \leq num_modalité_C_2 < long(C_2)$$

Autrement dit num_modalité_C2 doit varier de 0 à long(C2)−1.

Sur les variables 'education' et 'marital' prises précédemment comme exemple, on aurait :
'education' dont les modalités encodées sont : 0, 1, 2, 3
'marital' dont les modalités encodées sont : 0, 1, 2
La nouvelle variable 'education_marital' comporte alors toutes les combinaisons possibles entre les modalités de 'education' et celles de 'marital'.
Comme 'marital' possède 3 modalités, on obtient les étiquettes numériques :

$0 \times 3 + 0 = 0$
$0 \times 3 + 1 = 1$
$0 \times 3 + 2 = 2$
$1 \times 3 + 0 = 3$
$1 \times 3 + 1 = 4$
$1 \times 3 + 2 = 5$
$2 \times 3 + 0 = 6$
$2 \times 3 + 1 = 7$
$2 \times 3 + 2 = 8$
$3 \times 3 + 0 = 9$
$3 \times 3 + 1 = 10$
$3 \times 3 + 2 = 11$

On obtient donc bien au total $4 \times 3 = 12$ combinaisons possibles de modalités, chacune possédant un étiquette numérique unique dans la nouvelle variable 'education_marital'.
On applique ensuite le même processus à chacune des 21 paires de variables catégorielles.
À la fin, les 21 nouvelles variables créées sont :

'job_marital', 'job_education', 'job_contact', 'job_month', 'job_poutcome', 'job_campaign_int', 'marital_education', 'marital_contact', 'marital_month', 'marital_poutcome', 'marital_campaign_int', 'education_contact', 'education_month', 'education_poutcome', 'education_campaign_int', 'contact_month', 'contact_poutcome', 'contact_campaign_int','month_campaign_int', 'month_poutcome', 'poutcome_campaign_int'.

Ces 21 nouvelles variables sont alors ajoutées aux autres variables du jeu de données.
À ce stade, les 7 variables catégorielles restantes sont toujours présentes dans le jeu de

données : 'job', 'marital', 'education', 'contact', 'month', 'poutcome' et 'campaign_int'.

```
===== BILAN APRÈS CROISEMENT DES VARIABLES CATÉGORIELLES =====

Nombre total de croisements réalisés : 21

Variables créées par croisement :
- job_marital
- job_education
- job_contact
- job_month
- job_poutcome
- job_campaign_int
- marital_education
- marital_contact
- marital_month
- marital_poutcome
- marital_campaign_int
- education_contact
- education_month
- education_poutcome
- education_campaign_int
- contact_month
- contact_poutcome
- contact_campaign_int
- month_poutcome
- month_campaign_int
- poutcome_campaign_int

Nombre de variables catégorielles explicatives restantes : 7

Variables catégorielles explicatives restantes :
- job
- marital
- education
- contact
- month
- poutcome
- campaign_int

Nombre total de variables dans le jeu de données : 54
```

IV.5 One-Hot-Encoding des variables catégorielles restantes

Pour finir, on effectue un One-Hot Encoding sur les 7 variables catégorielles restantes dans le jeu de données : 'job', 'marital', 'education', 'contact', 'month', 'poutcome' et

'campaign_int'.
Le One-Hot Encoding consiste à créer, pour chaque modalité d'une variable catégorielle, une variable binaire indiquant par 1 si l'observation appartient à cette modalité et par 0 sinon.
Par exemple, pour une variable possédant trois modalités comme 'marital' dont les modalités sont : 'married', 'single' et 'divorced', le One-Hot Encoding crée trois variables binaires :

- 'marital_married'
- 'marital_single'
- 'marital_divorced'

Ainsi, une observation appartenant à la modalité 'single' sera représentée par : 'marital_married = 0', 'marital_single = 1', 'marital_divorced = 0'. Les 7 variables catégorielles restantes sont ensuite supprimées et remplacées par les nouvelles variables binaires obtenues par One-Hot Encoding.
Pour plus d'informations sur le One-Hot-Encoding, consulté directement l'étude "prédiction des prix de logement" réalisé par Luigy Ngomo à partir du jeu de données Ames Housing dataset.

```
===== BILAN APRÈS ONE-HOT ENCODING =====

Nombre de nouvelles variables créées par One-Hot Encoding : 42

Nouvelles variables créées :
- job_admin.
- job_blue-collar
- job_entrepreneur
- job_housemaid
- job_management
- job_retired
- job_self-employed
- job_services
- job_student
- job_technician
- job_unemployed
- job_unknown
- marital_divorced
- marital_married
- marital_single
- education_primary
- education_secondary
- education_tertiary
- education_unknown
- contact_cellular
```

```
- contact_telephone
- contact_unknown
- month_apr
- month_aug
- month_dec
- month_feb
- month_jan
- month_jul
- month_jun
- month_mar
- month_may
- month_nov
- month_oct
- month_sep
- poutcome_failure
- poutcome_other
- poutcome_success
- poutcome_unknown
- campaign_int_low
- campaign_int_medium
- campaign_int_high
- campaign_int_extreme

Nombre de variables catégorielles explicatives restantes : 0
Aucune variable catégorielle explicative restante.

Nombre total de variables dans le jeu de données : 89

Nouvelle taille du jeu de données :  (795211, 89)
```

V Optimisation des hyperparamètres

On commence par diviser le jeu de données en un ensemble d'entraînement contenant 80% des observations et un ensemble de test contenant les 20% restants. Cette division est effectuée de manière stratifiée selon la variable cible y, afin que les proportions de chaque classe observées dans le jeu de données initial soient approximativement conservées dans les ensembles d'entraînement et de test.

Nous présentons ci-dessous le résumé de la division :

```
===== DIVISION DU JEU DE DONNÉES =====

Taille du jeu de données complet : 795211
Taille de l'ensemble d'entraînement : 636168
Taille de l'ensemble de test : 159043

Nombre de variables explicatives : 88

Répartition de la variable cible dans le jeu complet :
y
0    0.8796
1    0.1204

Répartition de la variable cible dans l'ensemble d'entraînement :
y
0    0.8796
1    0.1204

Répartition de la variable cible dans l'ensemble de test :
y
0    0.8796
1    0.1204
```

Les modèles entrainés dans cette étude sont :

- XGBoost classifier
- LGBM cassifier classifier

La stratégie d'optimisation est la même (à quelques différentes près) que celle mise en oeuvre dans l'étude "prédiction des prix de logement" réalisé par Luigy Ngomo à partir du jeu de données Ames Housing dataset. Pour plus d'information, consulté directement cette étude.

V.1 Plages de recherche des hyperparamètres

Les meilleurs hyperparamètres de chacun des modèles sont recherchés dans les plages suivantes d'hyperparamètres :

XGBoost Classifier :

$$
\begin{aligned}
n_estimators &\in [300, 1500] \\
max_depth &\in [3, 10] \\
learning_rate &\in [0.01, 0.20] \\
min_child_weight &\in [1, 10] \\
subsample &\in [0.6, 1.0] \\
colsample_bytree &\in [0.6, 1.0] \\
gamma &\in [0, 5] \\
reg_alpha &\in [0, 5] \\
reg_lambda &\in [0.1, 10]
\end{aligned}
$$

LightGBM Classifier :

$$
\begin{aligned}
n_estimators &\in [300, 1500] \\
learning_rate &\in [0.01, 0.20] \\
num_leaves &\in [15, 127] \\
max_depth &\in [3, 12] \\
min_child_samples &\in [10, 100] \\
subsample &\in [0.6, 1.0] \\
colsample_bytree &\in [0.6, 1.0] \\
reg_alpha &\in [0, 5] \\
reg_lambda &\in [0, 10]
\end{aligned}
$$

La recherche d'hyperparamètres pour chaque modèle se fait avec optuna (pour une meilleur compréhension du fonctionnement de la recherche d'hyperparamètres avec optuna : voir l'étude "prédiction des prix de logement" réalisé par Luigy Ngomo à partir du jeu de données Ames Housing dataset).

V.2 Validation croisée stratifiée k-fold

Pour chaque combinaison d'hyperparamètres proposée par Optuna, une validation croisée stratifiée à 5 folds est effectuée. Le jeu de données d'entraînement est alors divisé en cinq sous-ensembles conservant approximativement la même proportion de chaque classe. Le modèle est successivement entraîné sur quatres folds puis évalué sur le dernier folds. Chacun des 5 folds sert donc une fois pour l'évaluation. A chaque évaluation, le F1-score du fold évalué est calculé. Ensuite la moyenne des cinq F1-score est retenue pour servir comme indicateur de la performance de la combinaison d'hyperparamètres.
Le meme processus est effectué pour chaque combinaison d'hyperparamètres, et la combinaison d'hyperparamètres ayant obtenu le meilleur F1-score moyen est conservée.
On rappel que le **F1-score** est une métrique qui combine la précision et le rappel.

La **précision** mesure, parmi les observations prédites positives par le modèle, la proportion qui est réellement positive :

$$\text{Précision} = \frac{VP}{VP + FP}$$

Le **rappel** mesure, parmi toutes les observations réellement positives, la proportion correctement identifiée par le modèle :

$$\text{Rappel} = \frac{VP}{VP + FN}$$

où :

- VP : vrais positifs ;
- FP : faux positifs ;
- FN : faux négatifs.

Le **F1-score** correspond à la moyenne harmonique de la précision et du rappel :

$$F1 = 2 \times \frac{\text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}}$$

Le F1-score varie entre 0 et 1. Une valeur proche de 1 indique de bonnes performances conjointes en précision et en rappel.

V.3 Temps d'optimisation et choix du nombre d'essais et de folds

Nous effectuons pour chaque modèle 25 essais optuna. Chaque essais comporte 5 entraînements. Donc pour un seul modèle, on réalise $25 \times 5 = 125$ entraînements. Et donc pour les 2 modèles cela fait $125 \times 2 = 250$ entraînements et l'equivalent en évaluation. Ce qui est assez modeste.
Cependant le jeu de données d'entraînement comporte 80% des données du jeu de données initiale, soit environ 636 168 clients. Avec un découpage à 5 folds, cela fait environ 127 233 clients par folds. Ainsi pour chaque combinaison d'hyperparamètres (chaque essai), le modèle est entrainé cinq fois sur une quantité d'environ $4 \times 127\ 233 = 508\ 932$ clients et évalué cinq fois sur une quantité d'environ 127 233.
Pour une seule combinaison d'hyperparamètres (un essai), cela peut donc déjà représenter un certain temps d'exécution. Mais alors pour 25 essais, puis pour chacun des deux modèles, cela peut représenter un certain temps de calcul. On comprends bien dans ce cas de figure qu'augmenter le nombre d'essais optuna (et/ ou le nombre de folds) contribue directement et fortement à faire exploser le temps d'exécution du programme d'optimisation des hyperparamètres. A en juger le temps d'exécution obtenu ci-dessous pour seulement 25 essais optuna par modèle et 5 folds.

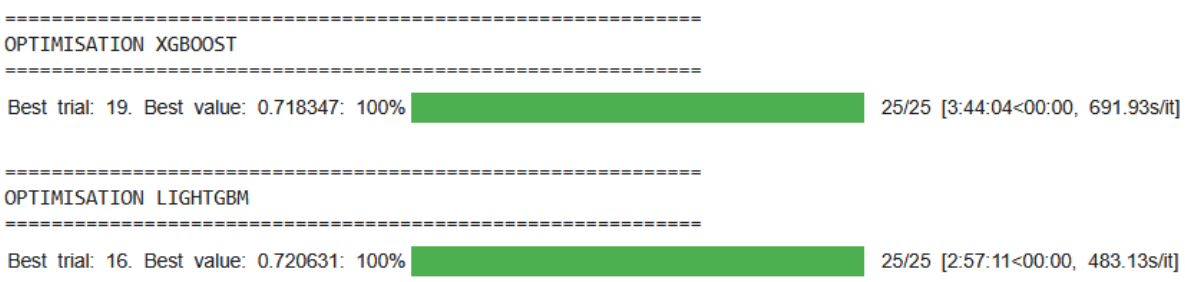


FIGURE 9 – Temps d'éxécution du tuning d'hyperparamètres par modèles

`TEMPS TOTAL DE RECHERCHE POUR LES 2 MODÈLES : environ 6 h 41 min 15 s`

Le choix des 25 et pas de 5, 10 ou 15 essais provient également d'un constat effectué lors d'une optimisation sur le même ensemble de données, mais réduit à 50 000 clients environ. En effet, sur 100 essais initiaux, le meilleur F1-score était généralement obtenu au cours des 25 premiers essais (avec 3 ou 5 folds), et cela pour chacun des modèles.
Les meilleurs hyperparamètres retenues pour chacun des modèles sont présentés ci-dessous. Ils seront utilisés pour la suite :

```
========================================
 BILAN FINAL DE L'OPTIMISATION
========================================
--- XGBoost ---
Meilleur F1-score moyen : 0.7183
Meilleurs hyperparamètres :
 n_estimators : 1351
 max_depth : 9
 learning_rate : 0.038091422761720235
 min_child_weight : 10
 subsample : 0.764088169035724
 colsample_bytree : 0.8981338423911418
 gamma : 0.5148967405837193
 reg_alpha : 0.8479076469387579
 reg_lambda : 2.153969873768789
--- LightGBM ---
Meilleur F1-score moyen : 0.7206
Meilleurs hyperparamètres :
 n_estimators : 1278
 learning_rate : 0.03707350270485297
 num_leaves : 109
 max_depth : 12
 min_child_samples : 50
 subsample : 0.8064114554738083
 colsample_bytree : 0.6580343694108768
 reg_alpha : 2.852662022754696
 reg_lambda : 7.088233096404097
```

VI Entrainement et évaluation finale des modèles

Les modèles sont reconfigurés avec les hyperparamètres retenues précédemment puis réentrainés sur l'ensemble d'entraînement complet.
Une fois l'entraînement effectué, les modèles sont évalués sur l'ensemble de test. La principale métrique utilisée pour comparer les performances des différents modèles est la ROC-AUC.

VI.1 De la probabilité prédite à la classification

Dans un problème de classification binaire comme le notre, la variable cible Y possède deux classes. Une classe qu'on peut appelé la classe positive (classe 1 ici) et une autre qu'on peut appelé la classe négative (classe 0). On a :

$$Y = \begin{cases} 1 & \text{si le client souscrit à un dépot à terme,} \\ 0 & \text{si le client ne souscrit pas à un dépot à terme} \end{cases}$$

Après l'entraînement d'un modèle, son évaluation sur l'ensemble de test permet d'obtenir pour chaque observation i un score de prédiction. Lorsque le modèle fournit des probabilités, celles-ci correspondent entre autre à la probabilité que l'observation appartienne à une classe sachant ses caractéristiques observées. On peut la notée :

$$\hat{p}_i = P(Y_i = 1 | X_i)$$

où X_i représente l'ensemble des caractéristiques disponibles pour l'observation i. Dans le cadre de notre étude, il s'agit de l'ensemble des caractéristiques disponibles pour un client telles que l'age, le solde moyen annuel, la présence d'un prêt immobilier ou personnel, etc. Ensuite, pour réellement classé les observations (ici les clients), on fixe un seuil de décision s. Et si la probabilité que l'observation i appartienne à la classe 1 sachant ses caractéristiques observées est supérieur au seuil de décision, alors l'observation i est prédite appartenir à la classe 1, sinon elle est prédite appartenir à la classe 0. Ce qui se traduit mathématiquement par :

$$\hat{Y}_i = \begin{cases} 1 & \text{si } \hat{p}_i \geq s, \\ 0 & \text{si } \hat{p}_i < s \end{cases}$$

Un seuil de $0,5$ est couramment utilisé par défaut pour la prédiction de classe dans les classifieurs probabilistes de scikit-learn, mais ce seuil peut être modifié en fonction de l'objectif métier et du compromis recherché entre faux positifs et faux négatifs.

VI.2 Influence du seuil de classification

Le choix du seuil joue un rôle important dans la classification finale.
Lorsque le seuil est élevé (par exemple $0,9$), la probabilité prédite doit etre elle aussi

importante pour que l'observation soit classée comme positive. Le nombre total d'observations prédites positives (TP+FP) aura donc tendance à diminuer. En général, cela va tendre à diminuer le nombre de faux positifs, mais peut aussi augmenter le nombre de faux négatifs : par exemple, certains véritables souscripteurs peuvent obtenir une probabilité inférieure au seuil (trop élevé) et être classés négatifs.
D'un autre coté, lorsque le seuil diminue, en général davantage d'observations sont classées positives (TP + FP). Cela permet souvent de détecter davantage de véritables positifs, mais au prix d'un plus grand nombre de faux positifs.
Le choix du seuil correspond donc à un compromis entre la détection des positifs et les erreurs de classification.
Bien que 0,5 puisse sembler être un seuil intuitif, celui-ci n'est pas nécessairement optimal, notamment lorsque les classes sont déséquilibrées ou lorsque les différents types d'erreurs de classification n'ont pas les mêmes conséquences.
Par exemple, dans le cas où les souscripteurs représentent seulement 12% des clients, le choix du seuil mérite une attention particulière.
De plus, si par exemple le fait de classer à tort un non-souscripteur comme souscripteur (faux positif) entraîne un coût important pour la banque, il peut être pertinent d'augmenter le seuil de décision dans le but de ne retenir comme souscripteurs potentiels que les clients auxquels le modèle attribue un score suffisamment élevé. Cela permet de réduire le nombre de faux positifs, au prix toutefois d'un risque plus important de ne pas détecter certains véritables souscripteurs (faux négatifs).

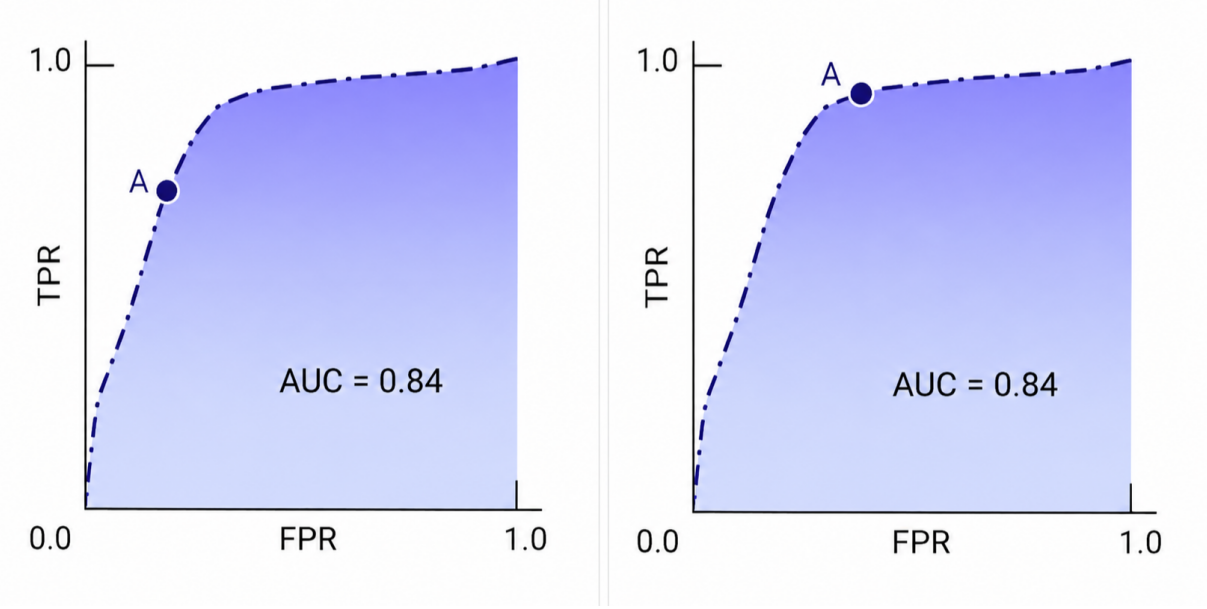


FIGURE 10 – Seuil de séparation et FPR associé

Par exemple, le seuil de la première image (le plus grand des deux) pourra etre privilégié au détriment de celui de la seconde dans un cas où les faux positifs sont très couteux. En effet, il est celui qui est associé à un FPR plus faible meme si le TPR aussi est réduit.
D'un autre coté, si les faux positifs sont peu couteux et qu'à l'inverse le fait de perdre ou

manqué des vraix positifs (faux négatifs) est couteux, le seuil de la figure de droite (le plus petit des deux) est le plus adapté. En effet c'est celui qui offre la plus grande valeur de TPR meme si c'est au détriment d'une FPR plus élevé.

VI.3 Construction et interprétation de la courbe ROC

La courbe ROC (Receiver Operating Characteristic) permet d'étudier les performances du modèle pour l'ensemble des seuils de classification possibles, plutôt que pour un seul seuil fixé arbitrairement.
Pour chaque seuil s, les probabilités prédites sont transformées en classes :

$$\hat{Y}_i(s) = \begin{cases} 1 & \text{si } \hat{p}_i \geq s, \\ 0 & \text{sinon} \end{cases}$$

À partir des classes obtenues, deux quantités sont calculées.
Taux de vrais positifs (TPR)
Le True Positive Rate correspond au rappel (Recall) :

$$TPR = \frac{TP}{TP + FN}$$

Il représente la proportion de véritables souscripteurs correctement identifiés par le modèle.
Taux de faux positifs (FPR)
Le False Positive Rate est défini par :

$$FPR = \frac{FP}{FP + TN}$$

Il représente la proportion de véritables non-souscripteurs que le modèle classe à tort comme souscripteurs.
Le TPR et le FPR sont calculés pour chaque valeur de seuil s. La courbe ROC est alors l'ensemble des points $(FPR(s), TPR(s))$ pour s variant entre 0 et 1.
Ainsi, chaque point de la courbe ROC correspond à un seuil de décision. Et la courbe représente le $TPR(s)$ en fonction du $FPR(s)$.

Lorsque le seuil diminue, davantage d'observations sont progressivement classées positives. Le TPR augmente, mais le FPR également.
Le modèle idéal serait capable d'obtenir simultanément : $TPR = 1$ et $FPR = 0$, c'est-à-dire identifier tous les véritables souscripteurs sans classer aucun non-souscripteur comme souscripteur. Une bonne courbe ROC se rapproche donc du coin supérieur gauche du graphique.

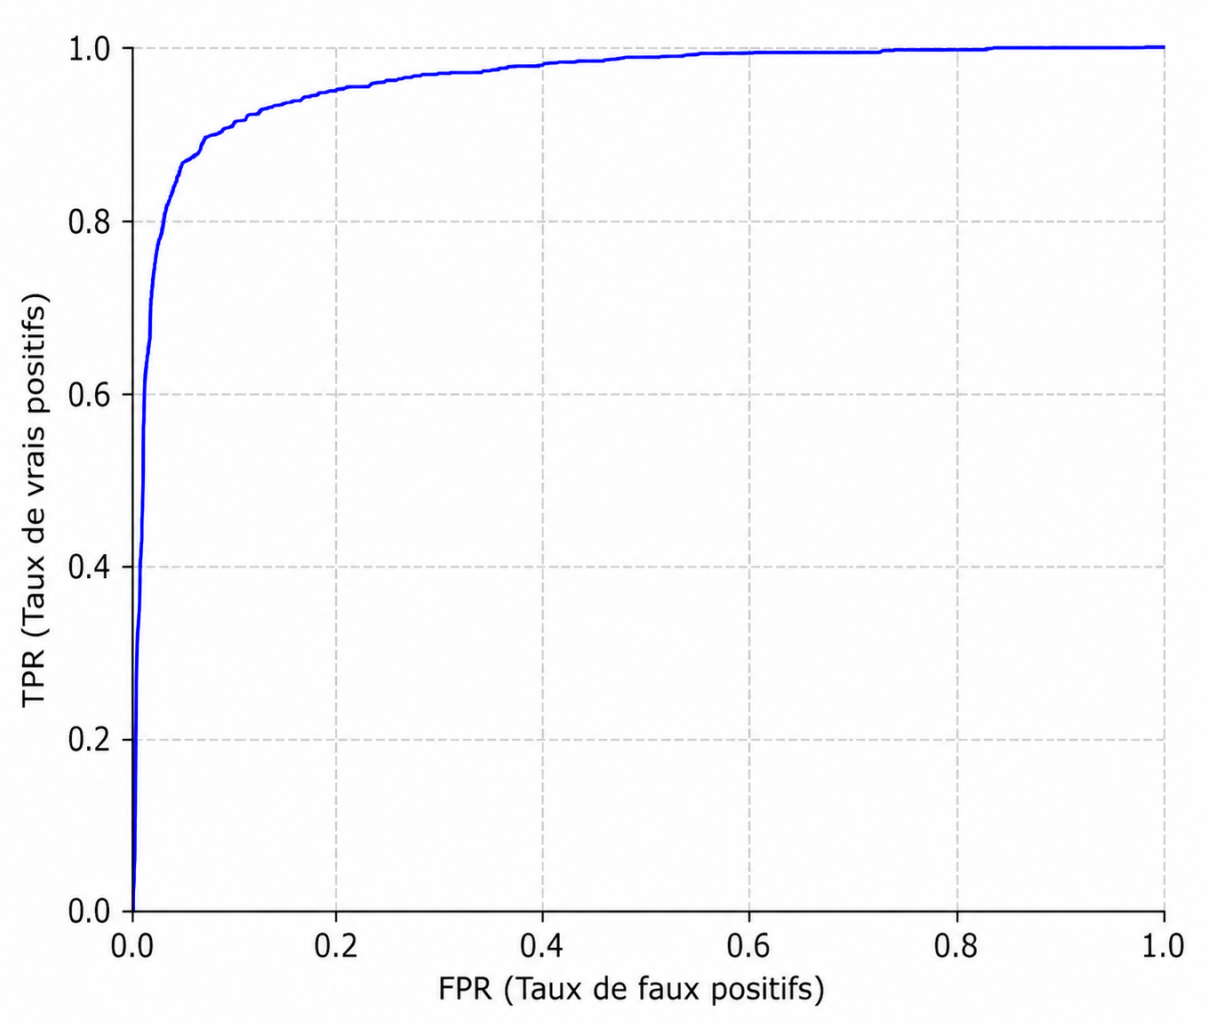


FIGURE 11 – Exemple de courbe ROC d'un bon modèle

VI.4 L'AUC : aire sous la courbe ROC

L'AUC (Area Under the Curve) correspond à l'aire située sous la courbe ROC. Elle synthétise en une seule valeur la capacité du modèle à discriminer les deux classes sur l'ensemble des seuils considérés.
Mathématiquement, elle peut s'écrire :

$$AUC = \int_0^1 TPR(FPR)\,\mathrm{d}(FPR)$$

Mais elle possède une interprétation probabiliste particulièrement intéressante :

$$\boxed{AUC = P(S(X^+) > S(X^-)) + \frac{1}{2}P(S(X^+) = S(X^-))}$$

où :

- X^+ est une observation choisie parmi les véritables positifs ;
- X^- est une observation choisie parmi les véritables négatifs ;

- $S(X)$ est le score attribué par le modèle.

En l'absence d'égalité de scores, cela se simplifie en :

$$\boxed{AUC = P(S(X^+) > S(X^-))}$$

Donc, l'aire sous la courbe (ROC-AUC) représente la probabilité qu'un véritable positif choisi au hasard reçoive un score supérieure à celui d'un véritable négartif choisi au hasard. Par exemple, dans le cas de notre étude, une $AUC = 0,96$ signifierait que, si l'on sélectionne aléatoirement un véritable souscripteur et un véritable non-souscripteur, le modèle a environ 96% de chances d'attribuer un score de souscription plus élevé au véritable souscripteur. L'AUC mesure donc avant tout la capacité de discrimination ou de classement du modèle entre les deux classes.

VI.5 L'AUC est comprise entre 0 et 1

On peut montrer mathématiquement que l'AUC est comprise entre 0 et 1.
Par définition :

$$TPR = \frac{TP}{TP + FN}, \text{ or } TP \geq 0 \text{ et } FN \geq 0$$

donc on a nécessairement :

$$0 \leq TP \leq TP + FN.$$

et en divisant par $TP + FN > 0$ on a :

$$\frac{0}{TP + FN} \leq \frac{TP}{TP + FN} \leq \frac{TP + FN}{TP + FN}.$$

donc :

$$\boxed{0 \leq TPR \leq 1}.$$

De même on a :

$$FPR = \frac{FP}{FP + TN},$$

et peut montrer que :

$$\boxed{0 \leq FPR \leq 1}.$$

La courbe ROC est donc contenue dans le carré :

$$[0, 1] \times [0, 1].$$

Et comme :

$$0 \leq TPR(FPR) \leq 1,$$

on peut intégrer les trois membres entre 0 et 1 :

$$\int_0^1 0\, d(FPR) \leq \int_0^1 TPR(FPR)\, d(FPR) \leq \int_0^1 1\, d(FPR).$$

Or :

$$\int_0^1 0\, d(FPR) = 0$$

et :

$$\int_0^1 1\, d(FPR) = 1.$$

On obtient donc :

$$0 \leq \int_0^1 TPR(FPR)\, d(FPR) \leq 1.$$

D'où :

$$\boxed{0 \leq AUC \leq 1}.$$

VI.6 Interprétation des valeurs de l'AUC

Une AUC égale à 1 correspond à une séparation parfaite : tous les véritables positifs obtiennent un score supérieur à tous les véritables négatifs.
Une AUC proche de 1 indique une très bonne capacité du modèle à discriminer les deux classes.
Une AUC égale à $0,5$ correspond à un modèle qui ne possède pas de pouvoir discriminant utile : son classement est équivalent à un classement aléatoire.
Enfin, une AUC inférieur à $0,5$ signifie que le modèle tend à classer les observations dans le sens opposé : les positifs reçoivent plus souvent des scores inférieurs aux négatifs. Ce cas est différent d'un simple modèle aléatoire ; en inversant le sens des scores, on pourrait théoriquement obtenir une AUC supérieure à $0,5$.

VI.7 Résultats sur l'ensemble test

VI.7.1 Comparaison rappel et AUC-ROC des deux modèles

```
============================================
 COMPARAISON DES MODÈLES SUR L'ENSEMBLE TEST
============================================
```

Modèle	Accuracy	Précision	Rappel	F1-score	ROC-AUC
XGBoost	0.9357	0.7603	0.6807	0.7183	0.9669
LightGBM	0.9359	0.7593	0.6844	0.7199	0.9673

Les performances des deux modèles sur l'ensemble de test sont très proches. LightGBM obtient néanmoins des résultats légèrement supérieurs à XGBoost pour l'Accuracy, le Rappel, le F1-score et l'AUC-ROC. XGBoost obtient uniquement une Précision légèrement supérieure. Les écarts restent toutefois très faibles et ne permettent pas d'affirmer qu'un modèle surpasse largement l'autre. Le Rappel est particulièrement intéressant puisqu'il mesure la capacité du modèle à identifier les clients qui souscrivent réellement à l'offre. LightGBM détecte environ 68,44 % des véritables souscripteurs, contre 68,07 % pour XGBoost.
Les deux modèles obtiennent une AUC-ROC très élevée, avec 0,9669 pour XGBoost et 0,9673 pour LightGBM. Ces résultats montrent qu'ils possèdent une excellente capacité à distinguer les clients souscripteurs des clients non-souscripteurs.
LightGBM obtient la meilleure AUC-ROC. L'écart (0,0004) reste cependant extrêmement faible. On peut donc considérer que les deux modèles démontrent des performances très similaires en termes de discrimination, avec un très léger avantage pour LightGBM.

VI.7.2 Rapports de classification

```
==============================================
 RAPPORTS DE CLASSIFICATION
==============================================
----- XGBoost -----

              precision    recall  f1-score   support

           0     0.9569    0.9706    0.9637    139888
           1     0.7603    0.6807    0.7183     19155

    accuracy                         0.9357    159043
   macro avg     0.8586    0.8257    0.8410    159043
weighted avg     0.9332    0.9357    0.9341    159043

----- LightGBM -----

              precision    recall  f1-score   support

           0     0.9574    0.9703    0.9638    139888
           1     0.7593    0.6844    0.7199     19155

    accuracy                         0.9359    159043
   macro avg     0.8584    0.8274    0.8419    159043
weighted avg     0.9335    0.9359    0.9344    159043
```

Le rapport de classification confirme les résultats précédents. Les deux modèles présentent des performances très similaires et sont particulièrement efficaces pour identifier les non-souscripteurs (classe 0). La détection des souscripteurs (classe 1) reste plus difficile, avec

un rappel d'environ 68%. Ce résultat peut notamment s'expliquer par le déséquilibre des classes. En effet, environ 88% des observations correspondent à des non-souscripteurs, contre seulement 12% de souscripteurs. La stratification utilisée lors de la séparation des données permet de conserver approximativement ces proportions dans les ensembles d'entraînement et de test. Le modèle dispose ainsi de beaucoup plus d'exemples de la classe 0 lors de son apprentissage, ce qui peut contribuer à une meilleure identification de cette classe.

VI.7.3 Matrices de confusion

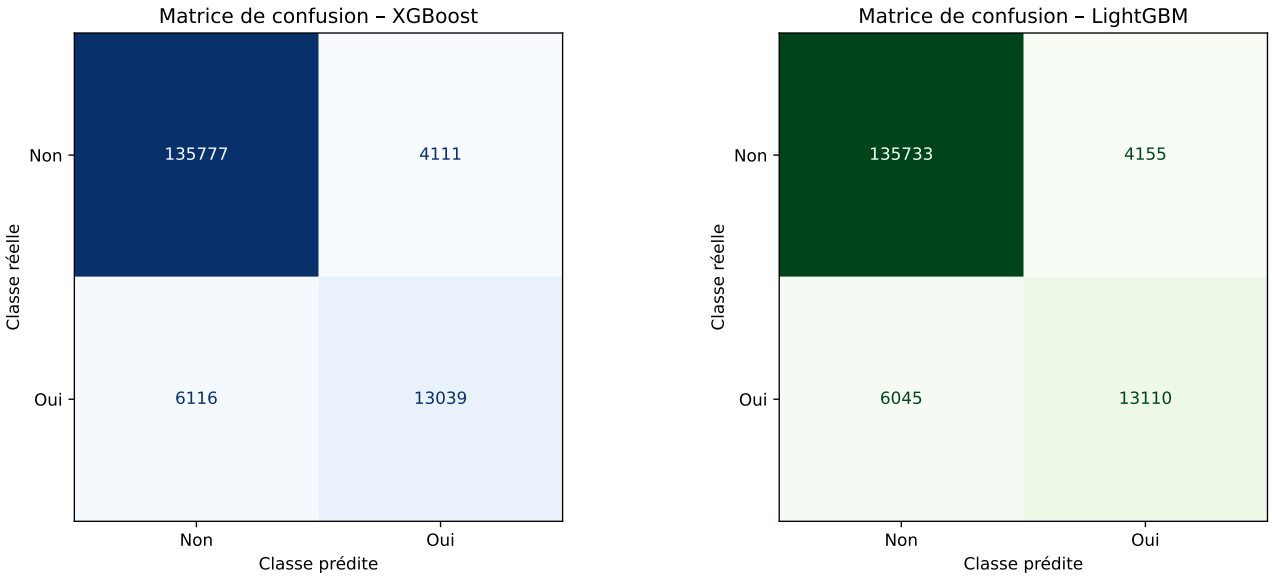


FIGURE 12 – Matrices de confusion des deux modèles de classification

Les deux modèles présentent des résultats très similaires. XGBoost identifie correctement 13 039 souscripteurs, contre 13 110 pour LightGBM. LightGBM détecte donc légèrement mieux la classe positive, ce qui est cohérent avec son rappel légèrement supérieur. En contrepartie, il génère un peu plus de faux positifs (4 155 contre 4 111). XGBoost produit quant à lui davantage de faux négatifs (6 116 contre 6 045). Ces résultats confirment que les performances des deux modèles sont très proches, avec un léger avantage pour LightGBM dans la détection des souscripteurs.

VI.7.4 Courbes ROC

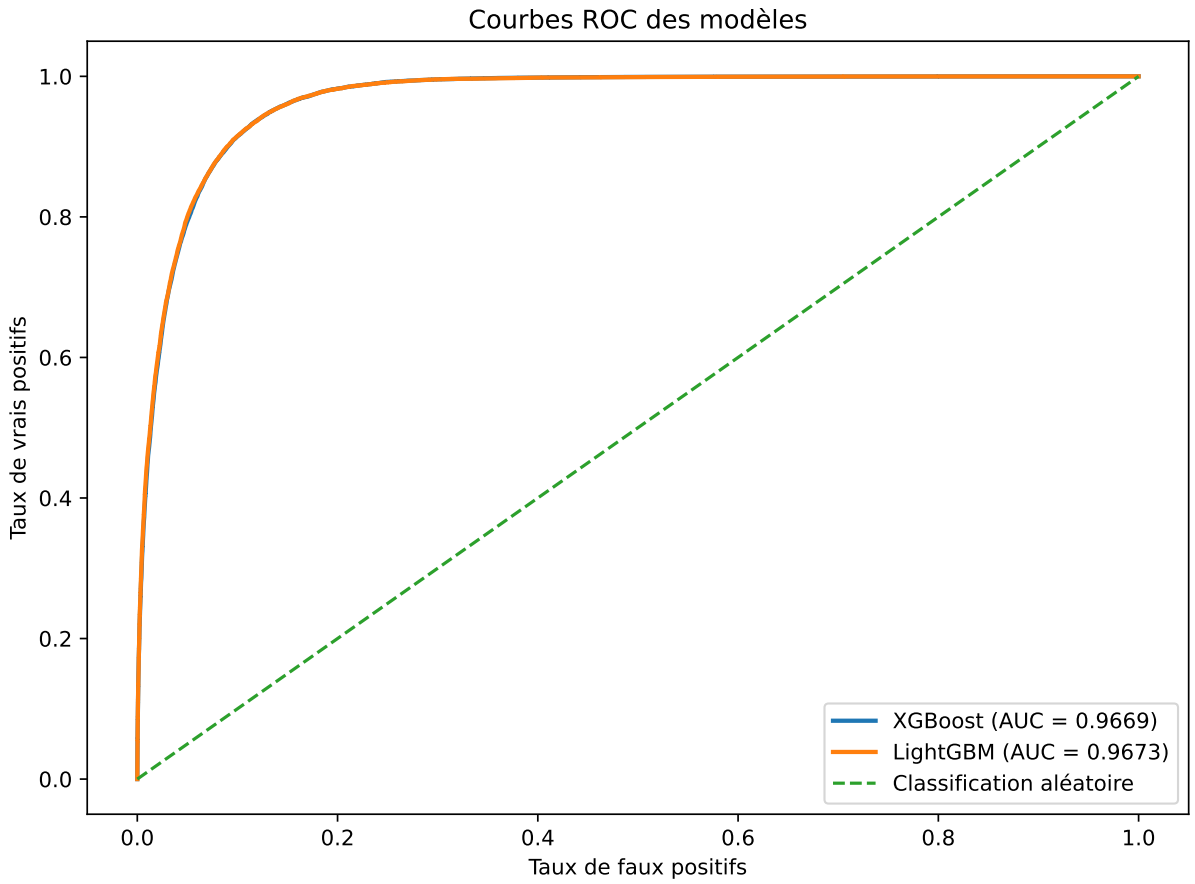


FIGURE 13 – Courbe ROC des deux modèles de classification

Les courbes ROC des deux modèles sont très proches du coin supérieur gauche, ce qui réflète une excellente capacité à distinguer les souscripteurs des non-souscripteurs pour différents seuils de classification. Les deux modèles sont également très largement au-dessus de la diagonale correspondant à une classification aléatoire. LightGBM obtient la meilleure AUC, mais l'écart de 0,0004 reste extrêmement faible. Les deux modèles possèdent donc des performances de discrimination quasiment équivalentes, avec un très léger avantage pour LightGBM.

VII Explication des résultats de prédictions du modèle avec SHAP

Dans cette partie nous cherchons à comprendre ce qui a amené le modèle (LightGBM) à produire les résultats de prédiction spécifique qu'il a retourné. Autrement dit, nous cherchons à connaitre comment le modèle est arrivé à sa prédiction. Et pour ce faire, nous utilisons **SHAP (SHapley Additive exPlanations)**, un outil largement utilisé en intelligence artificielle explicable (XAI), afin de fournir des explications à différents niveaux

qui vont de l'**explication globale** à l'**explication locale** en passant par l'**explication au niveau des variables**. L'explication globale permet de connaître quelles sont les variables les plus importantes globalement, c'est à dire celles qui contribuent le plus aux prédictions du modèle. L'explication au niveau des variables permet de comprendre comment une variable spécifique impacte les prédictions. Et enfin, l'explication locale vise à comprendre ce qui a amené le modèle à faire une prédiction particulière pour un client donné.

VII.1 Explication globale

VII.1.1 Moyenne des valeurs absolues des contributions SHAP d'une variable

La moyenne des valeurs absolues des contributions SHAP d'une variable est obtenue en prenant pour cette variable la moyenne de toutes les contributions SHAP de ses clients en valeur absolue. Cela donne mathématiquement :

$$\overline{|SHAP_j|} = \frac{1}{n}\sum_{i=1}^{n}|\phi_{ij}|$$

où :

- ϕ_{ij} représente la contribution SHAP de la variable j à la prédiction du client i ;
- n représente le nombre total de clients ;
- i : indice de l'observation (client) ;
- j : indice de la variable étudiée ;
- $|\phi_{ij}|$: valeur absolue de la contribution SHAP de la variable j à la prédiction du modèle pour le client i.
- $\overline{|SHAP_j|}$ représente la moyenne des valeurs absolues des contributions SHAP de la variable j.

Cette quantité mesure donc la force ou l'intensité moyenne avec laquelle une variable donnée influence les prédictions du modèle, sans tenir compte du sens positif (vers classe 1) ou négatif (vers classe 0) de cette influence.

Nous présentons ci-dessous les 9 premières variables avec les contributions moyennes des valeurs absolues SHAP les plus élevées :

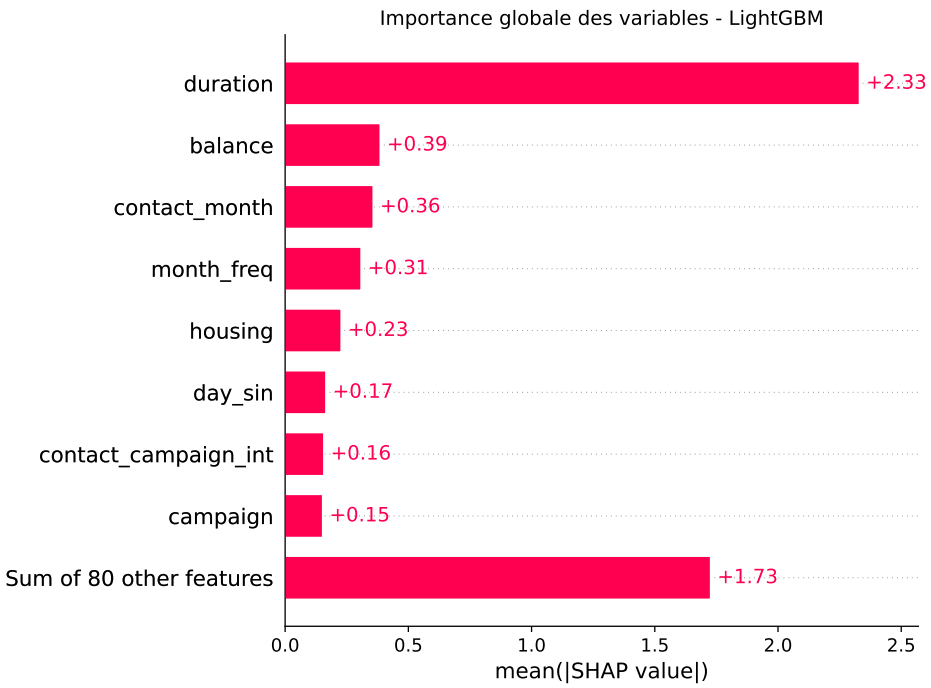


FIGURE 14 – Importance globale moyenne SHAP des variables

'duration' est la variable qui possède la plus grande contribution absolue moyenne (2.33). On voit donc que cette variable exerce de très loin une très grande influence globale sur les prédictions du modèle par rapport aux autres variables. Cela signifie que, en moyenne, la durée du dernier contact exerce une forte influence sur la prédiction de souscription ou non-souscription par le modèle.
À côté, les variables balance, 'contact_month', 'month_freq' et 'housing' affichent une contribution absolue moyenne assez moindre mais figurent néanmoins parmi les meilleures, suggérant donc que ces variables contribuent aussi de façon assez présente aux prédictions de souscription du modèle. Il peut être aussi intéressant de voir que des variables créées lors de l'étape de feature engineering, telles que 'contact_month' et 'contact_campaign_int', figurent parmi les variables les plus influentes. Cela montre que certaines des variables créées lors du feature engineering sont effectivement utilisées de manière importante par le modèle dans ses prédictions.
Enfin, la catégorie Sum of 80 other features ne représente pas une seule variable, mais le regroupement des 80 autres variables non affichées individuellement sur le graphique. Leur contribution absolue moyenne cumulée est importante (1.73), même si chacune de ces variables possède individuellement une contribution plus faible que celles présentées séparément.

VII.2 La valeur absolue maximale des contributions SHAP en valeur absolue d'une variable

La valeur absolue maximale des contributions SHAP en valeur absolue d'une variable est obtenue en prenant pour cette variable la plus grande valeur de SHAP parmi tous ses

clients en valeur absolue. Cela donne mathématiquement :

$$I_j^{\max} = \max_{i=1,\ldots,n} |\phi_{ij}|$$

où :

- $I_j^{\max}$: valeur absolue maximale des contributions SHAP en valeur absolue de la variable j ;
- n : nombre total de clients ;
- i : indice de client ;
- j : indice de la variable étudiée ;
- ϕ_{ij} : valeur SHAP de la variable j pour le client i ;
- $|\phi_{ij}|$: valeur absolue de la contribution de la variable j à la prédiction du modèle pour le client i.

Cette quantité mesure donc à quel point une variable peut exercer une influence exceptionnelle sur la prédiction d'au moins un client, même si globalement l'influence de cette variable est moindre.
Nous présentons ci-dessous les 9 premières variables avec la valeur absolue maximale des contributions SHAP en valeur absolue la plus élevée :

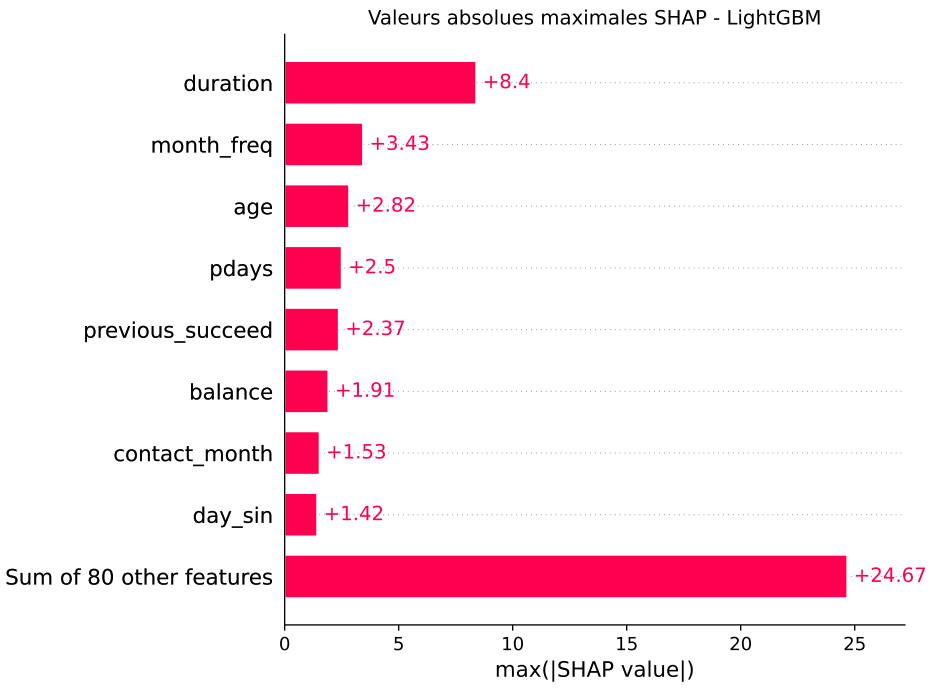


FIGURE 15 – Importance absolue SHAP des variables

Comme avec la moyenne des valeurs absolues des contributions SHAP, on peut voir que la variable 'duration' est également celle qui peut exercer la plus forte influence sur la prédiction d'au moins un client. Des variables telles que 'month_freq', balance et 'contact_month' continuent également de jouer un rôle important dans les prédictions de

certains clients.
Mais il peut être intéressant ici de voir aussi que des variables comme :

- 'age' : l'age du client,
- 'pdays' : le nombre de jours écoulé entre le dernier contact et la campagne précédente, et
- 'previous_succeed' : variable créée lors du feature engineering, qui est une variable binaire qui vaut 1 si la campagne précédente s'est terminée par un succès et 0 sinon,

qui globalement n'étaient pas parmi les variables les plus importantes, peuvent néanmoins avoir une contribution très importante pour au moins un client. Cela montre bien qu'une variable ayant globalement une influence relativement faible sur les prédictions du modèle peut néanmoins avoir une influence très forte sur la prédiction de certains clients.

VII.2.1 Graphique de synthèse de la distribution des valeurs SHAP des variables

Le beeswarm plot (ou summary plot) représente la distribution des valeurs SHAP de chaque variable pour l'ensemble des clients. Chaque point correspond à un client. Sa position indique l'influence de la variable sur la prédiction du modèle, tandis que sa couleur représente la valeur prise par cette variable (de très faible à très forte). Nous affichons ci-dessous le beeswarm plot pour certaines variables du dataset.

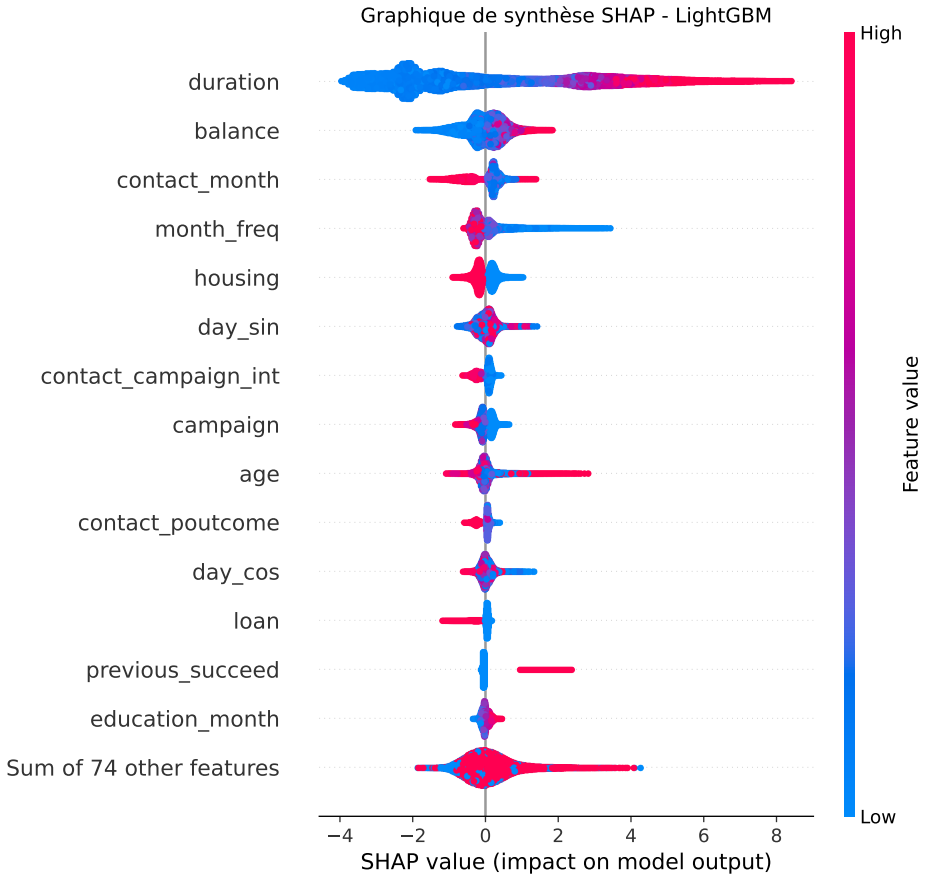


FIGURE 16 – Beeswarm plot des variables

duration :
Pour cette variable, qui est la plus influente globalement mais aussi celle qui peut exercer la plus forte influence individuellement, on peut voir que plus elle est faible, c'est-à-dire plus la durée du dernier appel est courte, plus le modèle a tendance à produire une contribution SHAP négative, poussant ainsi la prédiction vers la classe 0 (non-souscripteur). À l'inverse, on peut voir que les longues durées d'appel ont un impact différent. En effet, plus la durée de l'appel est élevée, plus sa contribution SHAP tend à être positive et peut devenir très importante, poussant fortement la prédiction du modèle vers la classe 1 (souscripteur). On peut néanmoins observer quelques exceptions, avec certaines durées d'appel relativement faibles associées à des contributions positives, mais avec beaucoup moins de force que lorsque la durée de l'appel est élevée.
balance :
Un phénomène similaire tend à se produire avec la variable balance. On peut constater que lorsque le solde annuel moyen du client est faible, la contribution SHAP de cette variable tend à être négative, poussant ainsi la prédiction du modèle vers la classe 0 (non-souscripteur). À l'inverse, lorsque le solde annuel moyen augmente, sa contribution tend à devenir positive, poussant davantage la prédiction vers la classe 1 (souscripteur). Cette tendance reste néanmoins moins marquée que pour 'duration', puisque la majorité des contributions de balance restent relativement proches de zéro.
housing :
La variable binaire 'housing' (yes ou no) indique si le client possède un prêt immobilier ou non. Cette variable a été codée en 1 pour yes et 0 pour no. Ainsi, la valeur élevée de cette variable (1) correspond aux clients possédant un prêt immobilier, tandis que la valeur faible (0) correspond aux clients qui n'en possèdent pas.
Sur le graphique, on distingue assez nettement que lorsque le client possède un prêt immobilier ('housing' = 1), les contributions SHAP sont principalement négatives, ce qui pousse la prédiction du modèle vers la classe 0 (non-souscripteur). À l'inverse, lorsque le client ne possède pas de prêt immobilier ('housing' = 0), les contributions SHAP tendent à être positives, poussant davantage la prédiction vers la classe 1 (souscripteur).
campaign :
La variable 'campaign', qui correspond au nombre de contacts effectués auprès du client pendant la campagne en cours, présente un comportement assez clair. Lorsque le nombre de contacts effectués est élevé, les contributions SHAP tendent à être négatives, poussant ainsi la prédiction du modèle vers la classe 0 (non-souscripteur). À l'inverse, lorsque le nombre de contacts est faible, les contributions SHAP tendent plutôt à être positives, poussant la prédiction vers la classe 1 (souscripteur). L'influence de cette variable reste toutefois relativement faible, puisque la majorité de ses contributions SHAP sont proches de zéro.
age :
La variable age présente un comportement plus ambigu que les variables précédentes. En effet, les valeurs élevées de l'âge sont associées aussi bien à des contributions SHAP négatives que positives. On observe néanmoins que certaines valeurs élevées de l'âge

peuvent avoir des contributions SHAP fortement positives, poussant ainsi la prédiction du modèle vers la classe 1 (souscripteur). À l'inverse, les âges plus faibles présentent majoritairement des contributions relativement proches de zéro.
Donc, contrairement à des variables comme 'campaign', la relation entre l'âge et la prédiction du modèle ne semble pas strictement monotone.

loan :

On observe nettement que lorsque le client possède un prêt personnel ('loan' = 1), les contributions SHAP sont négatives, poussant ainsi la prédiction du modèle vers la classe 0 (non-souscripteur). À l'inverse, lorsque le client ne possède pas de prêt personnel ('loan' = 0), les contributions SHAP sont principalement très proches de zéro. Donc, la présence d'un prêt personnel semble diminuer la propension du modèle à prédire un client comme souscripteur, tandis que son absence influence relativement peu la prédiction.

previous_succeed :

On observe très nettement que lorsque la campagne précédente s'est terminée par un succès ('previous_succeed' = 1), les contributions SHAP sont fortement positives, poussant ainsi la prédiction du modèle vers la classe 1 (souscripteur). À l'inverse, lorsque la campagne précédente ne s'est pas terminée par un succès ('previous_succeed' = 0), les contributions SHAP restent très proches de zéro, avec une légère tendance négative. Ainsi, un succès lors de la campagne précédente constitue un signal important en faveur de la souscription, tandis que son absence influence relativement peu la prédiction.
Autrement dit, le modèle ne raisonne pas symétriquement. Un succès passé est une information très forte en faveur d'une nouvelle souscription, mais l'absence de succès passé n'est pas, à elle seule, une information forte en faveur d'un refus.

VII.3 Explication au niveau des variables

Dans cette sous-section nous cherchons à comprendre de quelle manière une variable spécifique impacte les prédictions du modèle. Et pour se faire nous traçons les PDP (Partial Dependance Plot) de deux variables qui sont : 'duration' et 'balance'.

VII.3.1 Graphique de dépendance partielle

Le graphique de dépendance partielle permet de tracer $E[f(x)|\text{variable}]$ en fonction des valeurs prises par la variable, où :

- $f(x)$ représente la prédiction du modèle pour le client x,
- variable représente la variable étudiée et
- $E[f(x)|\text{variable}]$ la valeur moyenne des prédictions obtenues sur l'ensemble des clients pour une valeur donnée de cette variable.

Pour chaque valeur de "variable" étudiée, celle-ci est fixée pour tous les clients, tandis que leurs autres caractéristiques sont conservées. Ce graphique montre donc comment évolue, en moyenne, la probabilité prédite par le modèle en fonction des valeurs prises par une variable. Il permet ainsi de voir comment varie la probabilité de souscription lorsque les

valeurs de cette variable changent, et donc d'identifier quelles valeurs peuvent constituer de forts indicateurs de souscription.
Nous traçons et analysons ci-après les PDP des variables 'duration' et 'balance' :

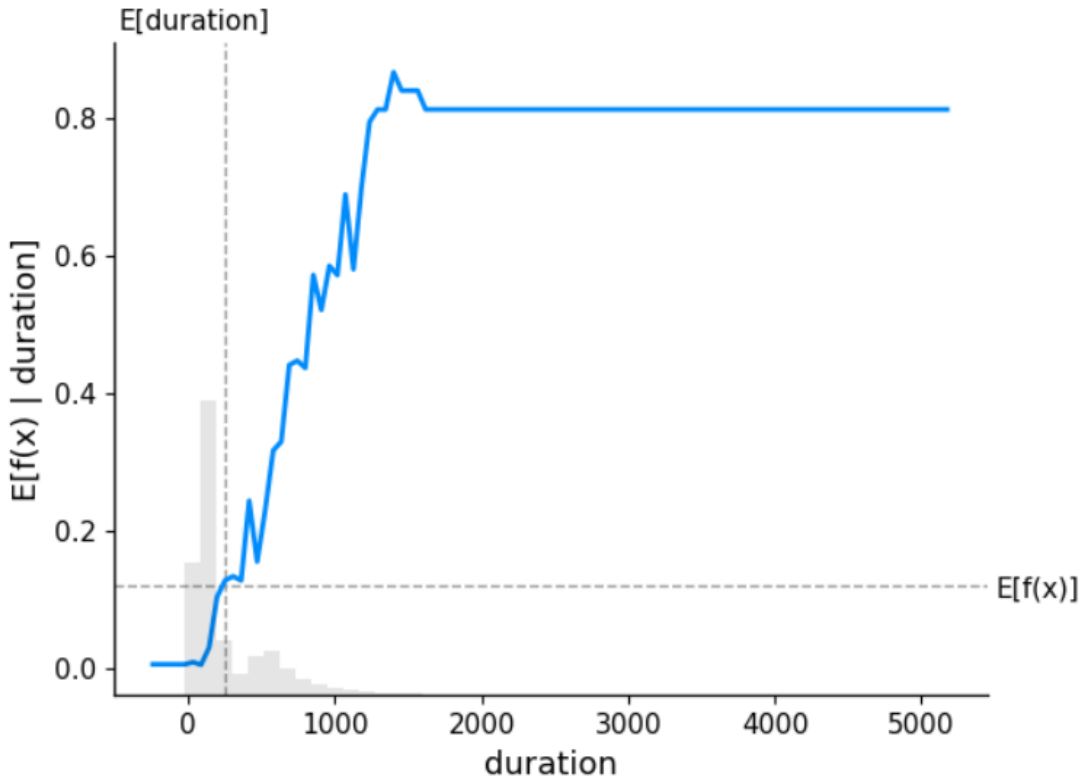


FIGURE 17 – Graphique de dépendance partielle de la variable 'duration'

On peut voir que la probabilité prédite de souscription augmente globalement avec la durée du dernier appel. Pour les durées d'appels faibles, la probabilité de souscription reste très faible, puis elle augmente très fortement à mesure que la durée de l'appel augmente (environ entre 300 et 1 400 secondes). À partir d'environ 1 400 - 1 500 secondes, la courbe atteint un plateau autour d'une probabilité de $0,8$ environ. A ce stade, augmenter encore la durée de l'appel n'augmente plus la probabilité d'être prédit comme souscripteur par le modèle. L'histogramme situé en arrière-plan montre également que les appels de très longue durée sont relativement rares, la majorité des observations étant concentrées sur des durées beaucoup plus faibles.

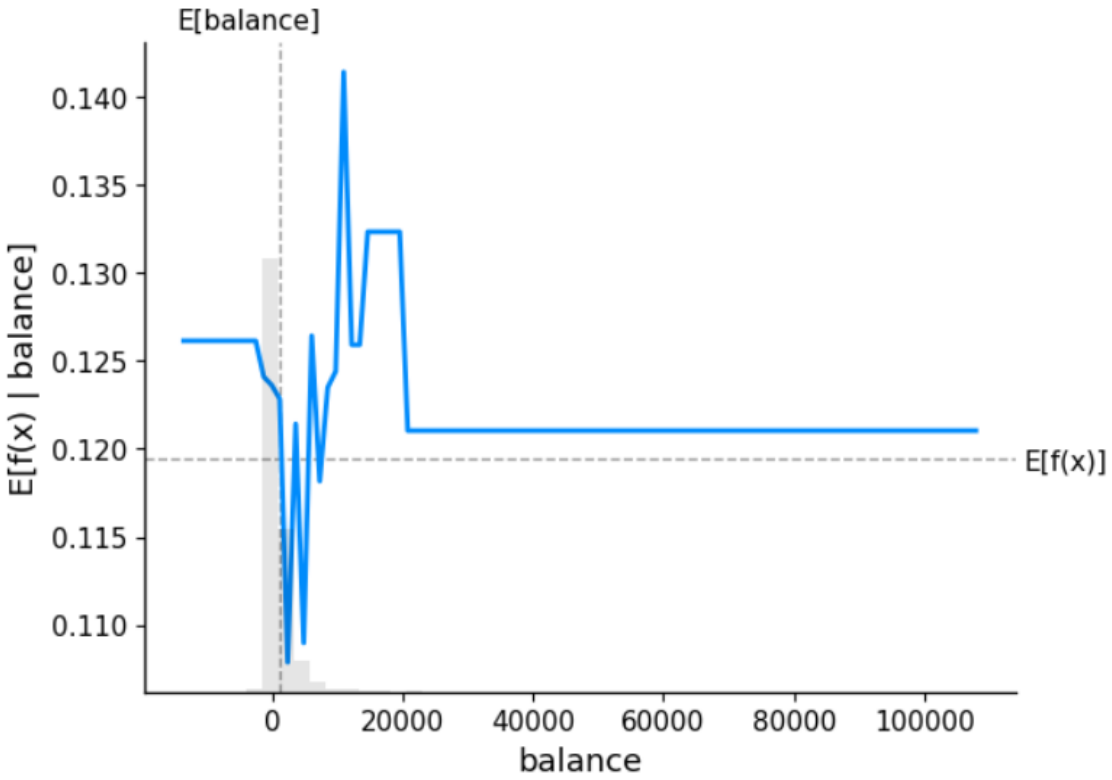


FIGURE 18 – Graphique de dépendance partielle de la variable 'balance'

Pour les valeurs négatives du solde moyen annuel, la probabilité d'être prédit comme souscripteur est autour de 12% et varie relativement peu.
Dans la zone de 0 à 20 000, la courbe devient très irrégulière : elle monte et descend, avec des probabilités approximativement comprises entre 11% et 14% et au delà d'environ 20 000 elle se stabilise autour de $12,1\%$ environ.
L'histogramme en arrière plan montre que la très grande majorité des clients est concentrée autour des faibles valeurs de solde moyen annuel. Il y a très peu d'observation pour les soldes extrêmement élevés. Néanmoins, pour certains soldes dans la fourchette 0 - 20 000, la probabilité de souscription semble présentée une tendance générale à la hausse, même si on observe successivement des hausses et des baisses.

VII.4 Explication locale

Dans cette sous-section, on cherche à comprendre, pour un client spécifique, comment chacune de ses variables a contribué à la prédiction finale du modèle. Pour ce faire, nous traçons le graphique des forces (**Force Plot**) du client dont nous cherchons à comprendre la prédiction.

VII.4.1 Graphique de forces (Force Plot) d'un client

Le **Force Plot** part de la valeur de référence du modèle $E[f(X)]$, puis montre la contribution de chaque variable à la prédiction finale. La formule peut s'écrire :

$$f(x_i) = E[f(X)] + \sum_{j=1}^{p} \phi_{ij}$$

où :

- ϕ_{ij} représente la valeur SHAP, c'est-à-dire la contribution de la variable j à la prédiction du modèle pour le client i ;
- $E[f(X)]$ représente la valeur de référence du modèle.

Cette valeur de référence correspond à la sortie moyenne du modèle sur l'ensemble des clients pris comme population de référence. Elle peut être estimée par :

$$E[f(X)] \approx \frac{1}{n} \sum_{k=1}^{n} f(x_k)$$

où :

- n représente le nombre de clients de la population de référence ;
- $f(x_k)$ représente la sortie du modèle pour le client k.

Cette valeur moyenne constitue alors le point de départ à partir duquel on cherche à expliquer la prédiction d'un client particulier.
Ainsi, pour un client donné, chaque variable est représentée avec sa contribution. Ces différentes contributions permettent de passer de la valeur de référence $E[f(X)]$ à la prédiction finale $f(x_i)$. Elles poussent la sortie du modèle dans des directions opposées : certaines caractéristiques poussent la sortie du modèle vers la classe 1 (Yes), tandis que d'autres la poussent vers la classe 0 (No).

VII.4.2 Graphique en cascade (Waterfall Plot) d'un client

Le Waterfall Plot repose sur le même principe que le Force Plot présenté précédemment. Il cherche également à expliquer une prédiction individuelle à partir de la valeur de référence $E[f(X)]$ et des différentes contributions SHAP permettant d'aboutir à la prédiction finale $f(x_i)$.
La différence réside principalement dans la manière dont ces contributions sont représentées. Alors que le Force Plot les représente comme des forces poussant la sortie du modèle dans des directions opposées, le Waterfall Plot les présente sous la forme d'une cascade de contributions successives.
On part de la valeur de référence $E[f(X)]$, puis chaque variable fait évoluer progressivement la sortie du modèle en fonction de sa valeur SHAP. Une contribution positive pousse la sortie vers la classe 1 (souscripteur), tandis qu'une contribution négative la pousse vers la classe 0 (non-souscripteur). Après avoir pris en compte l'ensemble de ces contributions, on obtient finalement la sortie du modèle $f(x_i)$ pour le client étudié.
La longueur des barres permet également d'identifier les variables ayant eu le plus d'influence sur cette prédiction individuelle. Le Waterfall Plot permet donc de visualiser étape par étape comment les différentes contributions SHAP font évoluer la sortie du modèle

depuis la valeur de référence $E[f(X)]$ jusqu'à la prédiction finale $f(x_i)$.

Nous présentons et expliquons ci-dessous les Force Plot et Waterfall Plot de deux clients aux résultats de préditions différents : un client prédit comme souscripteur (classe 1) et un autre prédit comme non-souscripteur (classe 0).

Client prédit comme souscripteur

```
=== CLIENT PRÉDIT YES ===
Indice : 14298
Classe prédite : 1
Probabilité de souscription : 0.7852
Valeur de référence E[f(X)] : -5.2666
```

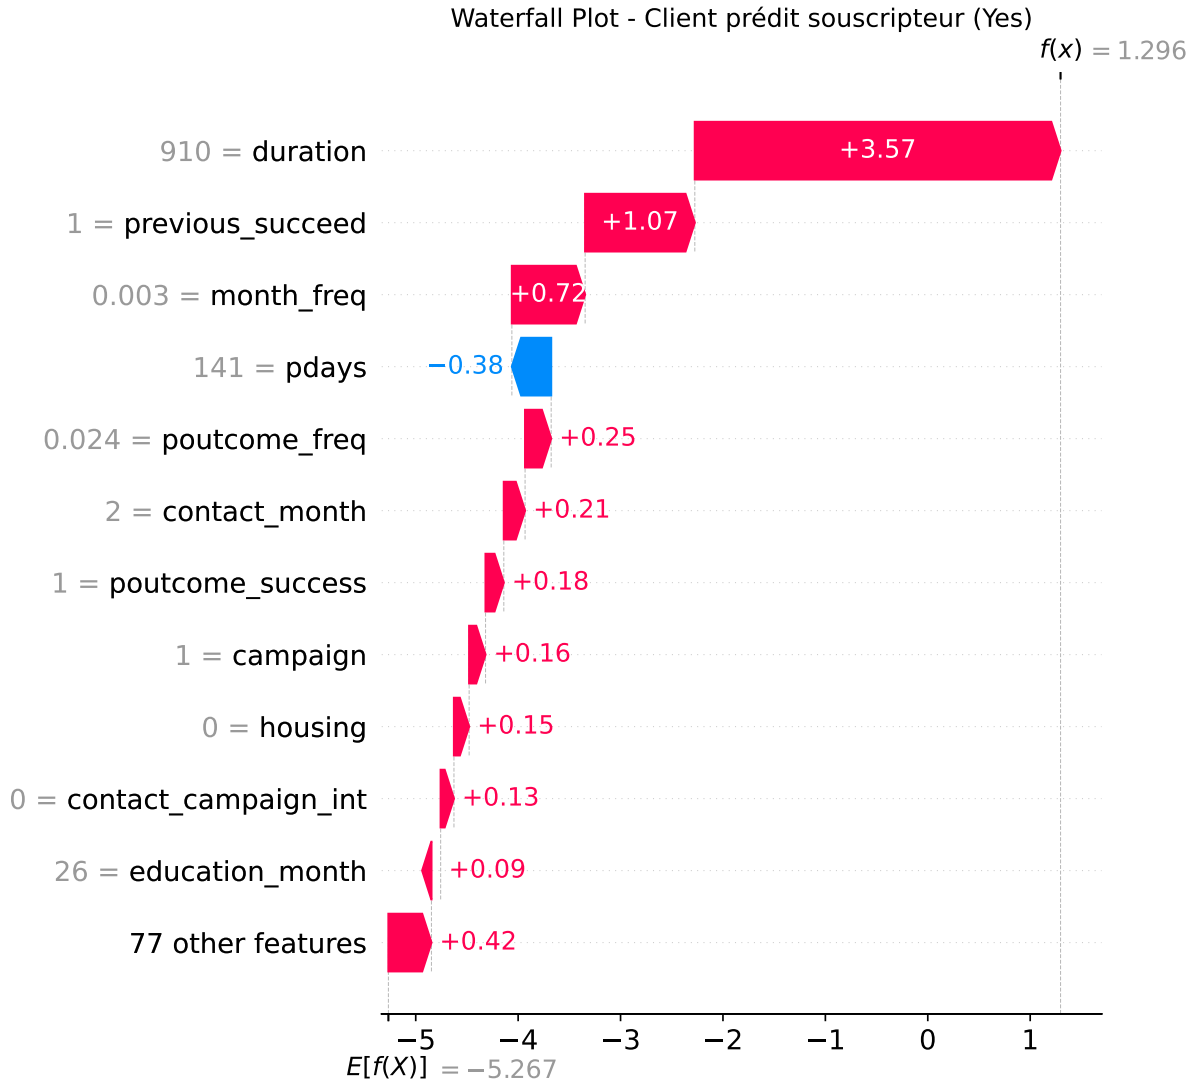


FIGURE 19 – Waterfall plot du client prédit comme souscripteur

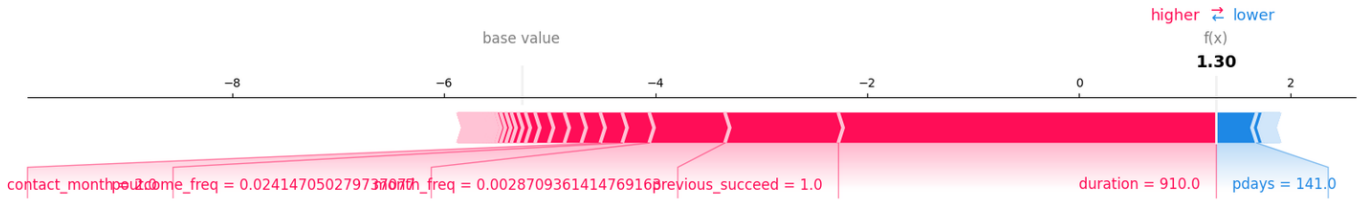


FIGURE 20 – Force plot du client prédit comme souscripteur

Ce client constitue un bon exemple de l'intérêt de SHAP pour l'interprétation d'une prédiction individuelle. Le modèle part d'une valeur de référence fortement orientée vers la non-souscription, avec $E[f(X)] \approx -5.27$. Cependant, les caractéristiques propres à ce client sont suffisamment importantes pour renverser cette tendance et faire évoluer la sortie du modèle jusqu'à $f(x) \approx 1.30$.
La variable *duration*, avec une durée d'appel de 910 secondes, joue le rôle principal dans cette évolution avec une contribution SHAP d'environ +3.57. Le succès de la campagne précédente ($previous_succeed = 1$) contribue également fortement à la prédiction avec une valeur SHAP d'environ +1.07. D'autres variables apportent des contributions positives plus faibles et renforcent progressivement la prédiction vers la classe 1 (souscripteur).
À l'inverse, certaines variables s'opposent à cette prédiction. C'est notamment le cas de $pdays = 141$, dont la contribution SHAP est d'environ −0.38. Son influence reste cependant trop faible pour compenser l'ensemble des contributions positives.
Ainsi, le Force Plot permet de visualiser le rapport de forces entre les variables poussant la sortie du modèle vers la classe 1 et celles la poussant vers la classe 0. Le Waterfall Plot permet quant à lui de visualiser étape par étape comment ces différentes contributions SHAP font évoluer la sortie du modèle depuis la valeur de référence $E[f(X)]$ jusqu'à la sortie finale $f(x)$.

Remarque :
Les valeurs $E[f(X)] \approx -5.27$ et $f(x) \approx 1.30$ représentées sur ces graphiques ne correspondent pas directement à des probabilités. Dans le cas présent, les valeurs SHAP expliquent la sortie brute du modèle, exprimée en log-odds. La valeur finale $f(x) \approx 1.30$ peut être transformée en probabilité à l'aide de la fonction logistique :

$$P(Y = 1 \mid X = x) = \frac{1}{1 + e^{-f(x)}}$$

Donc :

$$P(Y = 1 \mid X = x) = \frac{1}{1 + e^{-1.30}} \approx 0.785$$

soit une probabilité de souscription d'environ 78.5 %. Le modèle prédit donc finalement ce client comme souscripteur (classe 1).

Client prédit comme non-souscripteur

```
=== CLIENT PRÉDIT NO ===
Indice : 123086
Classe prédite : 0
Probabilité de souscription : 0.0001
Valeur de référence E[f(X)] : -5.2666
```

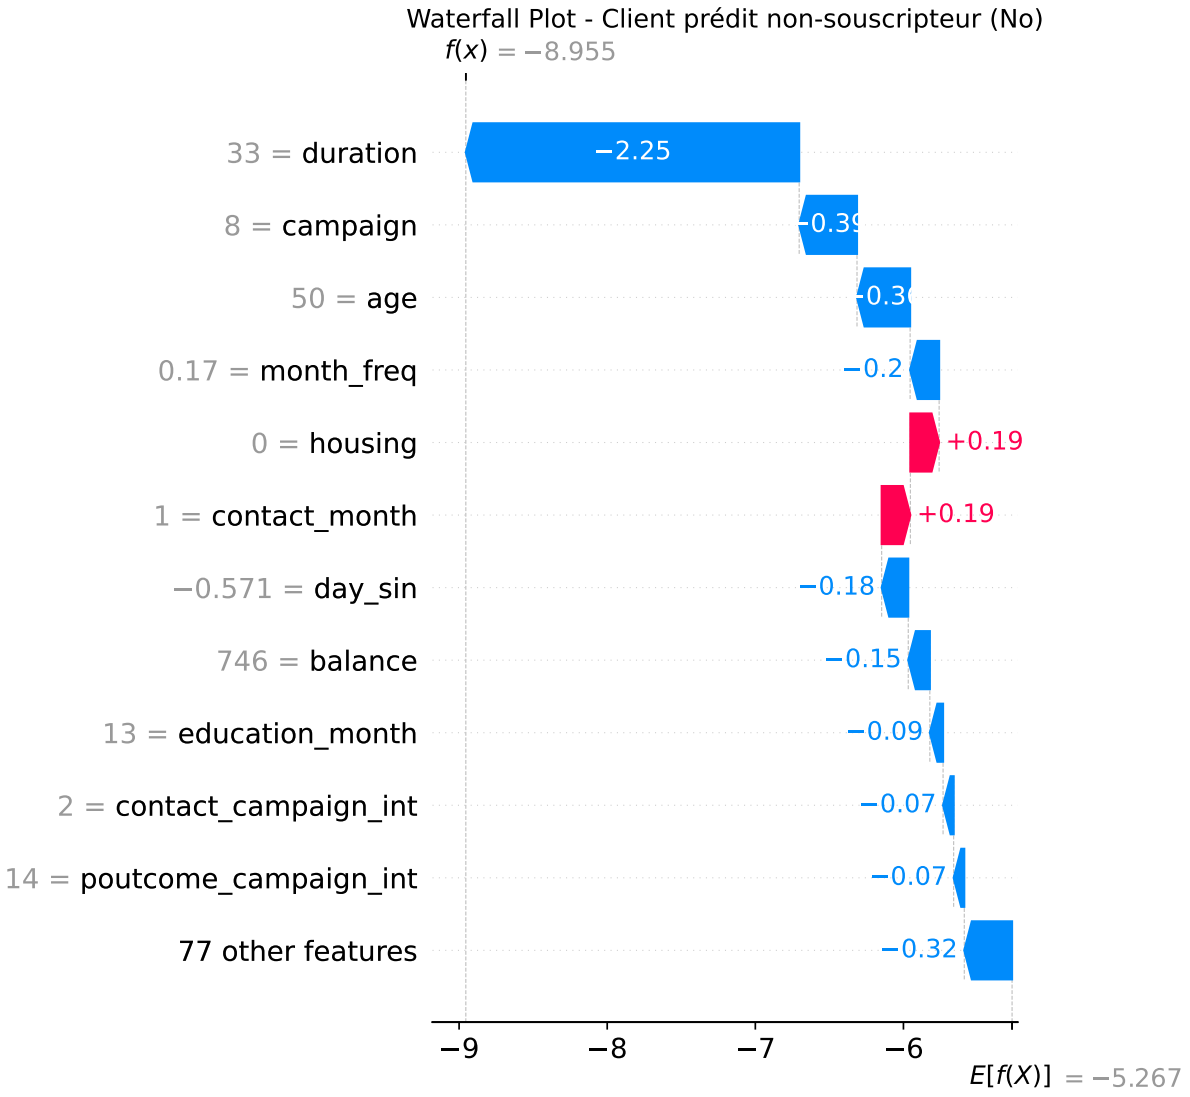


FIGURE 21 – Waterfall plot du client prédit comme non-souscripteur

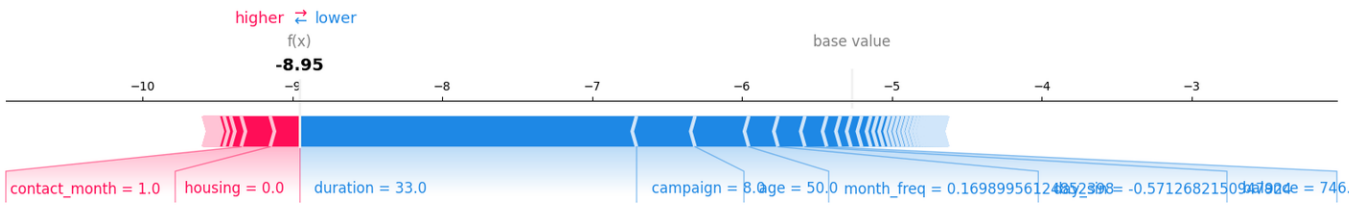


FIGURE 22 – Force plot du client prédit comme non-souscripteur

Ce client constitue un exemple dans lequel les caractéristiques individuelles renforcent la tendance initiale du modèle vers la non-souscription. Le modèle part d'une valeur de référence déjà orientée vers la classe 0, avec $E[f(X)] \approx -5.27$, puis les différentes contributions SHAP font diminuer davantage la sortie du modèle jusqu'à $f(x) \approx -8.95$.
La variable *duration*, avec une durée d'appel de seulement 33 secondes, joue le rôle principal dans cette évolution avec une contribution SHAP d'environ -2.25. D'autres variables, notamment *campaign* $= 8$, *age* $= 50$ et *month_freq* ≈ 0.17, apportent également des contributions négatives et renforcent par là meme la prédiction vers la classe 0 (non-souscripteur).
À l'inverse, certaines variables s'opposent à cette prédiction. C'est notamment le cas de *housing* $= 0$ et *contact_month* $= 1$, qui présentent chacune une contribution SHAP positive d'environ $+0.19$. Leur influence reste cependant trop faible pour compenser l'ensemble des contributions négatives.
Donc, les caractéristiques de ce client font évoluer la sortie du modèle de $E[f(X)] \approx -5.27$ jusqu'à $f(x) \approx -8.95$, conduisant finalement le modèle à prédire ce client comme non-souscripteur (classe 0).

Remarque :
Les valeurs $E[f(X)] \approx -5.27$ et $f(x) \approx -8.95$ représentées sur ces graphiques ne correspondent pas directement à des probabilités. Les valeurs SHAP expliquent ici la sortie brute du modèle, exprimée en log-odds. La valeur finale $f(x) \approx -8.95$ peut être transformée en probabilité à l'aide de la fonction logistique :

$$P(Y = 1 \mid X = x) = \frac{1}{1 + e^{-f(x)}}$$

Donc :

$$P(Y = 1 \mid X = x) = \frac{1}{1 + e^{8.95}} \approx 0.00013$$

soit une probabilité de souscription d'environ $0.013\,\%$, ce qui explique que le modèle prédise ce client comme non-souscripteur (classe 0).

Pour le client prédit comme souscripteur, une durée d'appel de 910 secondes apportait une contribution SHAP fortement positive d'environ $+3.57$, tandis que pour ce client prédit comme non-souscripteur, une durée d'appel de seulement 33 secondes apporte une contribution SHAP fortement négative d'environ -2.25. Cette comparaison illustre concrètement ce que l'analyse SHAP globale avait déjà mis en évidence, à savoir que la durée du dernier appel est une variable déterminante dans les prédictions du modèle. Ici, son influence peut être observée directement au niveau de deux individus spécifiques.

Références

[1] Ngomo, L., *Prédiction des prix de logement à partir du jeu de données Ames Housing*, Projet personnel de Data Science, réalisé entre mai et juillet 2026.

[2] Ngomo, L., *Analyse des ventes d'une enseigne de fournitures et d'équipements*, Projet personnel de Data Science, réalisé entre juillet et août 2026.

[3] Gautam, S., *Bank Marketing Dataset Full*, Kaggle. Disponible sur : https://www.kaggle.com/datasets/sushant097/bank-marketing-dataset-full/data (consulté en août 2026).

[4] Shamim, A., *Bank Term Deposit Subscription Prediction Dataset*, Kaggle. Disponible sur : https://www.kaggle.com/datasets/adilshamim8/binary-classification-with-a-bank-dataset/data (consulté en août 2026).

[5] Google for Developers, *Classification : ROC et AUC*, Machine Learning Crash Course. Disponible sur : https://developers.google.com/machine-learning/crash-course/classification/roc-and-auc?hl=fr (consulté en août 2026).

[6] Google for Developers, *Seuils et matrice de confusion*, Machine Learning Crash Course. Disponible sur : https://developers.google.com/machine-learning/crash-course/classification/thresholding?hl=fr (consulté en août 2026).

[7] Freakonometrics, *AUC*, Articles et ressources consacrés à l'Area Under the Curve (AUC). Disponible sur : https://freakonometrics.hypotheses.org/tag/auc (consulté en août 2026).

[8] Scikit-learn, *sklearn.metrics.auc*, Documentation officielle de Scikit-learn. Disponible sur : https://scikit-learn.org/stable/modules/generated/sklearn.metrics.auc.html (consulté en août 2026).

[9] Charpentier, A., *Balance and Calibration of Probabilistic Scores*, Support de présentation, WG Risk, ESSEC, 2026. Disponible sur : https://freakonometrics.hypotheses.org/files/2026/01/slides_ESSEC_2026_calib_compressed.pdf (consulté en août 2026).

[10] SHAP, *An Introduction to Explainable AI with Shapley Values*, Documentation officielle de SHAP. Disponible sur : https://shap.readthedocs.io/en/stable/example_notebooks/overviews/An%20introduction%20to%20explainable%20AI%20with%20Shapley%20values.html (consulté en août 2026).